

ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG



LUẬN VĂN TỐT NGHIỆP
NGÀNH HỆ THỐNG THÔNG TIN

ỨNG DỤNG TÓM TẮT VĂN BẢN
TRÊN TÀI NGUYÊN HỌC TẬP HỖ TRỢ
CHO SINH VIÊN NGÀNH HỆ THỐNG
THÔNG TIN

Sinh viên: Võ Huỳnh Thiên

MSSV: B2203472

Khóa: 48

Cần Thơ, 4/2026

**ĐẠI HỌC CẦN THƠ
TRƯỜNG CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG**

**LUẬN VĂN TỐT NGHIỆP
NGÀNH HỆ THỐNG THÔNG TIN**

**ỨNG DỤNG TÓM TẮT VĂN BẢN
TRÊN TÀI NGUYÊN HỌC TẬP HỖ TRỢ
CHO SINH VIÊN NGÀNH HỆ THỐNG
THÔNG TIN**

**Người hướng dẫn
PGS. TS. Nguyễn Thanh Hải**

Sinh viên: Võ Huỳnh Thiên

MSSV: B2203472

Khóa: 48

Cần Thơ, 4/2026

LỜI CẢM ƠN

Để hoàn thành bài luận văn này, trước hết em xin gửi lời cảm ơn chân thành đến các thầy cô Trường Công nghệ Thông tin & Truyền thông và Khoa Hệ thống Thông tin, đã trang bị cho em những kiến thức nền tảng cần thiết trong suốt thời gian học tập vừa qua.

Đặc biệt, em xin gửi lời cảm ơn sâu sắc nhất đến Thầy Nguyễn Thanh Hải. Cảm ơn Thầy đã trực tiếp hướng dẫn, dành thời gian xem xét và đưa ra những nhận xét, góp ý cụ thể để em có thể khắc phục các thiếu sót trong quá trình thực hiện đề tài “Ứng dụng tóm tắt văn bản trên tài nguyên học tập hỗ trợ cho sinh viên ngành Hệ thống thông tin”. Nhờ sự định hướng của Thầy, em đã giải quyết được những vướng mắc kỹ thuật và hoàn thiện ứng dụng đúng tiến độ.

Bên cạnh đó, em cũng xin gửi lời cảm ơn đến các bạn bè thân thiết, đặc biệt là tập thể lớp Hệ thống thông tin khóa 48 đã luôn đồng hành, chia sẻ tài liệu và lời tri ân đặc biệt và sâu sắc nhất đến gia đình. Cảm ơn cha mẹ và những người thân yêu đã luôn là hậu phương vững chắc, bao dung và tạo mọi điều kiện tốt nhất cả về vật chất lẫn tinh thần để em có thể yên tâm học tập, theo đuổi con đường mình đã chọn.

Mặc dù đã nỗ lực hết mình để nghiên cứu và hoàn thiện đề tài, nhưng do giới hạn về mặt thời gian cũng như kinh nghiệm thực tiễn còn hạn hẹp, cuốn báo cáo và ứng dụng chắc chắn không tránh khỏi những thiếu sót. Em rất mong nhận được sự lượng thứ và những lời góp ý quý báu từ Hội đồng đánh giá cùng quý Thầy Cô để hệ thống được tối ưu hơn, đồng thời giúp em rút ra những bài học kinh nghiệm quý giá cho chặng đường công việc sau này.

Em xin chân thành cảm ơn!

LỜI CAM ĐOAN

Em tên là Võ Huỳnh Thiên, mã số sinh viên B2203472, tác giả của đề tài luận văn. Em xin cam kết các nội dung sau đây là đúng sự thật:

1. Đề tài luận văn này là sản phẩm nghiên cứu của riêng cá nhân em. Công trình nghiên cứu này chưa từng được tác giả nào khác sử dụng để nộp hoặc bảo vệ ở bất kỳ cấp học nào.
2. Mọi nguồn tài liệu tham khảo, số liệu trích dẫn từ các nghiên cứu trước đó đều được ghi nhận rõ ràng và trích dẫn đầy đủ trong Danh mục tài liệu tham khảo.

Em xin hoàn toàn chịu trách nhiệm về lời cam đoan của mình.

Cần Thơ, ngày ... tháng ... năm 20...

Người cam đoan

Võ Huỳnh Thiên

TÓM TẮT

Kỷ nguyên số mang lại sự bùng nổ của tài nguyên học tập, nhưng đồng thời tạo ra "nghịch lý của sự dư thừa tri thức". Sinh viên khối ngành Hệ thống Thông tin đang phải đối mặt với tình trạng quá tải khi tiếp cận hàng ngàn trang giáo trình phức tạp. Dù các Mô hình Ngôn ngữ Lớn (LLMs) thể hiện năng lực tổng hợp thông tin xuất sắc, việc ứng dụng trực tiếp chúng vào học thuật bị cản trở bởi rủi ro "ảo giác thông tin" (hallucination) – hiện tượng AI sinh ra các nội dung sai lệch thực tế nhưng với văn phong cực kỳ thuyết phục.

Để giải quyết triệt để thách thức này, luận văn xây dựng hệ thống Trợ lý học tập thông minh (AI Study Assistant) dựa trên hai giải pháp công nghệ cốt lõi. Thứ nhất, hệ thống ứng dụng kiến trúc Sinh văn bản tăng cường truy xuất (RAG) kết hợp Trí nhớ Lai. Kiến trúc này đóng vai trò như một "mỏ neo tri thức", buộc LLM chỉ được phép hội thoại và tạo sinh dựa trên tài liệu gốc. Thứ hai, luận văn đề xuất phương pháp Tóm tắt lai (Hybrid Summarization) mang tính đột phá. Bằng cách tích hợp Từ điển chuyên ngành vào thuật toán đồ thị TextRank thông qua tham số `base_bonus`, hệ thống tạo ra một "lực hấp dẫn toán học" khóa chặt các thuật ngữ khoa học, trước khi sử dụng LLM để làm mượt mạch văn. Hơn thế nữa, dựa trên luồng dữ liệu này, luận văn đã phát triển "Hệ sinh thái Zero-Token", tái sử dụng ma trận đồ thị để tự động trích xuất Sơ đồ tư duy (Mindmap) và Thẻ ôn tập (Flashcard) mà không phát sinh chi phí điện toán đám mây.

Thực nghiệm trên các tập dữ liệu chuyên ngành và bộ chuẩn hóa toàn cầu XLSum-Vietnamese chứng minh hệ thống đạt kết quả vượt trội. Tại ngưỡng trọng số tối ưu `base_bonus = 1.0`, hệ thống đạt chỉ số ROUGE tiệm cận các mô hình SOTA (như mT5, ViT5) nhưng với chi phí huấn luyện bằng 0 (Zero-training cost). Công kiểm duyệt chống ảo giác bằng kỹ thuật LLM-as-a-Judge – đạt độ tương quan 87.9% với chuyên gia – khẳng định tính minh bạch và độ an toàn tuyệt đối của thông tin. Khảo sát thực tiễn cho thấy ứng dụng giúp sinh viên tiết kiệm hơn 70% thời gian đọc hiểu tài liệu, mở ra một giải pháp EdTech tối ưu và khả thi để triển khai tại các cơ sở giáo dục đại học.

Từ khóa: Tóm tắt lai (Hybrid Summarization), RAG, TextRank, Từ điển chuyên ngành (Domain Dictionary), LLM-as-a-Judge, Zero-training cost, Ảo giác thông tin.

ABSTRACT

The digital era brings an explosion of learning resources, inadvertently creating a "paradox of knowledge redundancy". Students in Information Systems are facing cognitive overload when dealing with thousands of pages of complex textbooks. Although Large Language Models (LLMs) demonstrate excellent synthesis capabilities, their direct application in academia is hindered by the risk of "information hallucination" – a phenomenon where AI generates factually incorrect content in a highly convincing tone.

To thoroughly address this challenge, this thesis develops an Intelligent AI Study Assistant based on two core technologies. First, the system implements a Retrieval-Augmented Generation (RAG) architecture integrated with Hybrid Memory. This acts as a "knowledge anchor," forcing the LLM to generate responses strictly based on the provided source documents. Second, the study proposes a groundbreaking Hybrid Summarization method. By integrating a Domain Dictionary into the TextRank algorithm via the `base_bonus` parameter, the system creates a "mathematical gravitational pull" that locks in core scientific terminologies before employing the LLM to refine the text's fluency. Furthermore, building upon this foundation, the thesis develops a "Zero-Token Ecosystem," reusing graph data to automatically extract Concept Maps (Mindmaps) and Cloze Flashcards without incurring additional cloud computing costs.

Experiments on domain-specific datasets and the global benchmark XLSum-Vietnamese demonstrate outstanding results. At the optimal weight `base_bonus` = 1.0, the system achieves ROUGE scores approaching State-of-the-Art models (such as mT5, ViT5) but with a Zero-training cost. An anti-hallucination evaluation gate utilizing the LLM-as-a-Judge technique—which achieved an 87.9% correlation with human experts—confirms the absolute transparency and safety of the information provided. Practical surveys indicate that the application saves students over 70% of their reading time, paving an optimal and feasible EdTech solution for deployment in higher education institutions.

Keywords: Hybrid Summarization, RAG, TextRank, Domain Dictionary, LLM-as-a-Judge, Zero-training cost, Information Hallucination.

MỤC LỤC

CHƯƠNG 1	TỔNG QUAN ĐỀ TÀI.....	1
1.1	Đặt vấn đề.....	1
1.2	Mục tiêu nghiên cứu.....	2
1.3	Đối tượng và phạm vi nghiên cứu.....	2
1.3.1	Đối tượng nghiên cứu.....	2
1.3.2	Phạm vi dữ liệu.....	3
1.3.3	Phạm vi kỹ thuật.....	3
1.4	Đóng góp của đề tài.....	3
1.4.1	Về mặt khoa học và phương pháp luận.....	3
1.4.2	Về mặt thực tiễn.....	3
1.5	Bố cục của luận văn.....	4
CHƯƠNG 2	CƠ SỞ LÝ THUYẾT	5
2.1	Tổng quan về Tóm tắt tự động văn bản (Automatic Text Summarization)	5
2.2	Từ điển chuyên ngành (Domain Dictionary) trong cấu trúc dữ liệu	5
2.3	Thuật toán đồ thị TextRank và Topic-Sensitive PageRank	6
2.4	Kiến trúc Retrieval-Augmented Generation (RAG) và Quản lý ngữ cảnh	7
2.4.1	Truy xuất thưa (Sparse Retrieval) vs Truy xuất đặc (Dense Retrieval)	7
2.4.2	Kiến trúc Trí nhớ Lai (Hybrid Memory) trong đối thoại	8
2.4.3	Cơ chế sinh câu hỏi tự động (AQG) và Thẻ ghi nhớ (Flashcard)	9
2.5	Kỹ thuật Điều khiển Mô hình Ngôn ngữ trong hệ thống đối thoại	10
2.5.1	Nhận diện ý định (Intent Recognition).....	10
2.5.2	Kỹ thuật thiết kế chỉ thị (Prompt Engineering).....	11
2.6	Mô hình Ngôn ngữ Lớn (LLMs) và Kiến trúc Gemini	11
2.7	Các độ đo đánh giá Hệ thống (Evaluation Metrics)	11
2.7.1	Các độ đo từ vựng học (ROUGE & BLEU)	11
2.7.2	RAG Kiểm duyệt độ tin cậy và Đánh giá LLM-as-a-Judge	11
CHƯƠNG 3	PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT.....	13
3.1	Kiến trúc tổng quát và Luồng dữ liệu hệ thống.....	13
3.2	Kỹ thuật Tiền xử lý dữ liệu và Vector hóa.....	15
3.2.1	Phân tách từ vựng tiếng Việt (Tokenization)	16
3.2.2	Phân mảnh văn bản trượt gối đầu (Sliding Window Chunking).....	16

3.3	Đề xuất Thuật toán Tóm tắt lai (Hybrid Summarization) kết hợp tập từ vựng chuyên ngành	16
3.3.1	Cá nhân hóa đồ thị văn bản dựa trên từ điển chuyên ngành (Domain-driven Personalization).....	16
3.3.2	Kỹ thuật Prompt Engineering để làm mượt văn bản.....	20
3.4	Xây dựng Pipeline Kiến trúc sinh văn bản tăng cường truy xuất (RAG)	21
3.4.1	Cơ chế định tuyến ý định đa tầng (Multi-layer Intent Routing)	24
3.4.2	Tối ưu hóa ma trận truy xuất	24
3.4.3	Quản lý bộ nhớ hội thoại lai (Hybrid Conversational Memory).....	24
3.5	Cơ chế Đánh giá và Cảnh báo ảo giác 2 lớp (Anti-Hallucination Gate).....	25
3.6	Các tiện ích học tập gia tăng dựa trên tái sử dụng dữ liệu (Zero-Token Features)	25
3.7	Bảng tổng hợp cấu hình tham số hệ thống	25
CHƯƠNG 4 THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ		27
4.1	Hiện thực hóa hệ thống và Giao diện ứng dụng.....	27
4.1.1	Giao diện điều hướng tổng thể.....	27
4.1.2	Phân hệ Tóm tắt văn bản Lai (Hybrid Summarization)	28
4.1.3	Trợ lý hỏi đáp RAG và Đánh giá độ trung thực.....	30
4.1.4	Trình diễn Hệ sinh thái học tập "Zero-Token".....	31
4.2	Môi trường và Tập dữ liệu thực nghiệm	33
4.2.1	Môi trường thực nghiệm	33
4.2.2	Các tập dữ liệu (Datasets)	33
4.3	Kịch bản 1: Tinh chỉnh siêu tham số (Hyperparameter Tuning).....	35
4.4	Kịch bản 2: Đánh giá phương pháp Tóm tắt lai (Hybrid Summarization).....	38
4.5	So sánh đa tiêu chí với các nghiên cứu tương đương (SOTA Models)	42
4.6	Kịch bản 3: Đánh giá phân hệ Kiến trúc sinh văn bản tăng cường truy xuất (RAG).....	44
4.6.1	Đánh giá năng lực các module lõi.....	44
4.6.2	Đánh giá độ trung thực tự động (LLM-as-a-Judge): "Cuộc đấu trí giữa Máy và Người"	45
4.6.3	Thực nghiệm đối chứng (Ablation Study): TF-IDF so với Dense Embedding	48
4.6.4	Phân tích lỗi (Error Analysis) của phân hệ RAG.....	49
4.7	Phân tích chi phí và thời gian thực thi (Performance Profiling)	50
4.8	Đánh giá trải nghiệm người dùng cuối (User Study / UX Evaluation).....	52

4.8.1	Đặc điểm mẫu khảo sát	52
4.8.2	Đánh giá tính khả dụng bằng Thang đo SUS (System Usability Scale)	53
4.8.3	Phân tích giá trị thực tiễn và tính năng cốt lõi	54
4.8.4	Ghi nhận hạn chế và Đề xuất từ người dùng (User Feedback)	56
CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		58
5.1	Kết luận và Kết quả đạt được	58
5.2	Hạn chế của đề tài.....	59
5.3	Hướng phát triển tương lai	60

DANH MỤC HÌNH

Hình 2.1: Mô hình biểu diễn từ điển chuyên ngành (Domain Dictionary) ứng dụng trong chuyên ngành HTTT.....	6
Hình 2.2: Sơ đồ cải tiến TextRank với trọng số cá nhân hóa.	7
Hình 2.3: Kỹ thuật phân mảnh văn bản trượt (Sliding Window Chunking).....	8
Hình 2.4: Lưu đồ Trí nhớ Lai.....	9
Hình 2.5: Sơ đồ cơ chế nhận diện ý định lai (Hybrid Intent Recognition) trong hệ thống đối thoại.....	10
Hình 3.1 Sơ đồ kiến trúc tổng thể và luồng dữ liệu trung gian của hệ thống AI Study Assistant.	15
Hình 3.2: Lưu đồ thuật toán thể hiện sự can thiệp của lực từ trường <code>base_bonus</code> vào chuỗi Markov để hút các từ khóa chuyên ngành.....	18
Hình 3.3: Biểu đồ hoạt động (Activity Diagram) minh họa "Mô neo tri thức" RAG và cơ chế Trí nhớ Lai (Hybrid Memory).	20
Hình 3.4: Biểu đồ hoạt động chi tiết luồng định tuyến và Kiến trúc sinh văn bản tăng cường truy xuất (RAG) của hệ thống.	22
Hình 4.1: Giao diện khởi tạo của hệ thống AI Study Assistant.	27
Hình 4.2: So sánh kết quả giữa phương pháp trích xuất (TextRank) và tạo sinh (AI Gemini).....	28
Hình 4.3: Module đánh giá chất lượng tóm tắt tự động.....	29
Hình 4.4: Giao diện tương tác hỏi đáp dựa trên tài liệu (RAG Assistant).....	30
Hình 4.5: Phân tích ngữ cảnh trích xuất và chỉ số Faithfulness.	31
Hình 4.6: Giao diện Bản đồ tư duy (Mindmap) trực quan hóa cấu trúc tài liệu.	32
Hình 4.7: Giao diện Bộ thẻ ôn tập điền khuyết (Cloze Flashcards) sinh tự động từ từ điển chuyên ngành.....	33
Hình 4.8: Sự biến thiên của điểm số ROUGE-L theo hệ số trọng số chuyên ngành <code>base_bonus</code> trên tập dữ liệu.	36
Hình 4.9: Phân tích khoảng cách miền (Domain Gap) giữa dữ liệu chuyên ngành IT và dữ liệu XLSum thông thường khi thay đổi siêu tham số.	37
Hình 4.10: Tổng quan điểm số ROUGE-L trung bình của ba phương pháp tóm tắt.	39
Hình 4.11: Chi tiết các độ đo ROUGE-1, ROUGE-2 và ROUGE-L cho từng phương pháp.	40

Hình 4.12: Biểu đồ hộp thể hiện sự phân bố điểm số của các phương pháp thử nghiệm.	40
Hình 4.13: Biểu đồ Radar so sánh tổng hợp năng lực trích xuất đa chiều của các phương pháp.	41
Hình 4.14: So sánh hiệu năng của phương pháp Tóm tắt Lai (Đề xuất) với các mô hình SOTA (mT5[14], ViT5[9]) trên cùng tập dữ liệu XLSum-Vietnamese [8].	43
Hình 4.15: Biểu đồ cột chi tiết số lượng mẫu đạt các mức điểm đánh giá từ 1 đến 5.	45
Hình 4.16: Phân phối tỷ lệ độ trung thực (Faithfulness) của các câu trả lời sinh ra từ hệ thống RAG.	46
Hình 4.17: Cuộc đấu trí giữa Máy và Người - Biểu đồ phân tán minh họa sự tương quan 87.9% giữa điểm số của Giám khảo AI và Chuyên gia.	47
Hình 4.18: Phân tích thời gian thực thi trung bình trên một vòng lặp truy vấn - phản hồi.	51
Hình 4.19: Tối ưu hóa độ trễ thời gian thực thi nhờ cơ chế Nhận diện Ý định Lai (Regex kết hợp LLM.....	52
Hình 4.20: Tổng hợp mức độ phân bổ ý kiến đánh giá tính khả dụng theo thang đo SUS.....	53
Hình 4.21: Khảo sát mức độ tối ưu hóa thời gian học tập của hệ thống so với đọc thủ công.	55
Hình 4.22: Đánh giá của người dùng về các tính năng nổi bật nhất của hệ thống. ..	56

DANH MỤC BẢNG

Bảng 2.1: So sánh đặc trưng của hai phương pháp tóm tắt tự động.	5
Bảng 3.1: Các tham số cấu hình cốt lõi của hệ thống AI Study Assistant.....	25
Bảng 4.1: Thống kê số lượng mẫu tập dữ liệu XLSum-Vietnamese	34
Bảng 4.2: Ma trận phân loại tập dữ liệu Kiến trúc sinh văn bản tăng cường truy xuất RAG (datarag).....	34
Bảng 4.3: Kết quả đánh giá độ đo ROUGE của 3 phương pháp trên tập dữ liệu chuyên ngành	38
Bảng 4.4: Bảng So sánh hiệu năng (ROUGE scores) trên tập dữ liệu chuẩn XLSum-Vietnamese	42
Bảng 4.5: So sánh hiệu suất truy xuất (Retrieval Performance) giữa 2 phương pháp	48
Bảng 4.6: Ma trận phân loại lỗi (Error Taxonomy) trên tập dữ liệu đánh giá	49

DANH MỤC TỪ CHUYÊN NGÀNH

Viết tắt	Giải thích
AI	Trí tuệ nhân tạo (Artificial Intelligence)
API	Giao diện lập trình ứng dụng (Application Programming Interface)
BERTScore	Độ đo đánh giá mức độ tương đồng ngữ nghĩa ẩn dựa trên mô hình ngôn ngữ BERT
BLEU	Độ đo đánh giá tự động dựa trên độ chính xác của văn bản dịch / sinh ra (BiLingual Evaluation Understudy)
GPU	Bộ xử lý đồ họa (Graphics Processing Unit)
HTTT	Hệ thống thông tin (Information Systems)
IT	Công nghệ thông tin (Information Technology)
LCS	Chuỗi con chung dài nhất (Longest Common Subsequence)
LLM	Mô hình Ngôn ngữ Lớn (Large Language Model)
LMS	Hệ thống quản lý học tập (Learning Management System)
NLG	Tạo sinh ngôn ngữ tự nhiên (Natural Language Generation)
NLP	Xử lý ngôn ngữ tự nhiên (Natural Language Processing)
RAG	Sinh văn bản tăng cường truy xuất (Retrieval-Augmented Generation)
Regex	Biểu thức chính quy (Regular Expression)
ROUGE	Độ đo đánh giá chất lượng tóm tắt tự động dựa trên độ phủ (Recall-Oriented Understudy for Gisting Evaluation)
SOTA	Mức độ phát triển tiên tiến nhất / Mô hình hiện đại nhất (State-of-the-Art)
SUS	Thang đo tính khả dụng của hệ thống (System Usability Scale)
TF-IDF	Tần suất xuất hiện của từ - Nghịch đảo tần suất văn bản (Term Frequency - Inverse Document Frequency)
UI/UX	Giao diện người dùng / Trải nghiệm người dùng (User Interface / User Experience)

CHƯƠNG 1 TỔNG QUAN ĐỀ TÀI

1.1 Đặt vấn đề

Nghịch lý của sự dư thừa tri thức: Sự bùng nổ của tài nguyên học tập số khiến sinh viên HTTT rơi vào trạng thái quá tải: hàng ngàn trang giáo trình chuyên ngành dường như "đề bẹp" người học. Từ thực trạng này, một bài toán cấp bách được đặt ra: "Làm sao để nắm bắt cốt lõi một giáo trình 500 trang chỉ trong 5 phút mà không bị AI 'ảo giác' đánh lừa?". Nhằm giải quyết bài toán này, các Mô hình Ngôn ngữ Lớn (LLMs) đang được ứng dụng rộng rãi như một công cụ đắc lực để tóm tắt và tra cứu tri thức tự động [1].

Tuy nhiên, mặc dù các LLMs hiện đại thể hiện năng lực hiểu và tạo sinh ngôn ngữ tự nhiên (NLG) vượt trội, chúng vẫn tồn tại một khiếm khuyết nghiêm trọng cản trở việc ứng dụng trực tiếp trong môi trường học thuật chuyên sâu: hiện tượng "ảo giác thông tin" (Hallucination). Ảo giác xảy ra khi mô hình sinh ra các thông tin sai lệch về mặt thực tế, không tồn tại trong dữ liệu đầu vào hoặc dữ liệu huấn luyện, nhưng lại được diễn đạt dưới một văn phong mang tính thuyết phục cao [2]. Đối với sinh viên ngành HTTT, việc tiếp nhận sai các khái niệm kỹ thuật cốt lõi (như kiến trúc cơ sở dữ liệu, thuật toán máy học) do ảo giác của trí tuệ nhân tạo có thể dẫn đến những sai lầm nghiêm trọng trong nhận thức và thực hành thực tế.

Để khắc phục rào cản này, kiến trúc Sinh văn bản tăng cường truy xuất (Retrieval-Augmented Generation - RAG) đã được đề xuất như một giải pháp tối ưu cho các tác vụ đòi hỏi lượng kiến thức chuyên môn lớn (knowledge-intensive tasks). Thay vì phụ thuộc hoàn toàn vào tham số bộ nhớ tĩnh (parametric memory) của LLMs, kiến trúc RAG buộc mô hình phải truy xuất thông tin từ một cơ sở dữ liệu ngoại vi độc lập trước khi tiến hành tạo sinh câu trả lời [2]. Cơ chế này giúp giới hạn phạm vi sinh văn bản của mô hình, đảm bảo hệ thống phản hồi dựa trên các nguồn tài liệu có thật và minh bạch, qua đó giảm thiểu tối đa hiện tượng ảo giác. Bên cạnh đó, các hệ thống RAG hội thoại truyền thống thường gặp hạn chế về "cửa sổ ngữ cảnh" (context window), khiến mô hình dễ dàng "quên" các thông tin đã trao đổi trong các phiên học tập kéo dài [16]. Đồng thời, việc đảm bảo độ tin cậy tuyệt đối của hệ thống trước rủi ro "ảo giác" vẫn là một bài toán hóc búa cần có cơ chế kiểm duyệt chặt chẽ [17].

Bên cạnh quá trình truy xuất, việc tóm tắt tự động các tài liệu chuyên ngành cũng gặp khó khăn trong việc bảo toàn các thuật ngữ chuyên môn. Các nghiên cứu gần đây chỉ ra rằng, việc tích hợp từ điển chuyên ngành (Domain Dictionary) vào quá trình xử lý ngôn ngữ tự nhiên sẽ giúp định hướng sự tập trung (attention) của hệ thống vào các thực thể quan trọng, từ đó nâng cao đáng kể độ chính xác của văn bản đầu ra [3]. Ngoài ra, để tối ưu hóa trải nghiệm học tập, các tri thức sau khi được hệ thống

tóm tắt cần được tận dụng để tạo ra các tiện ích học tập chủ động (như sơ đồ trực quan hay thẻ ghi nhớ) nhằm hỗ trợ sinh viên ôn tập hiệu quả hơn.

Xuất phát từ các cơ sở lý luận trên, đề tài "Ứng dụng tóm tắt văn bản trên tài nguyên học tập hỗ trợ cho sinh viên ngành Hệ thống Thông tin" được thực hiện. Đề tài hướng tới việc phát triển một hệ thống trí tuệ nhân tạo lấy Tóm tắt văn bản và Hỏi đáp RAG làm trọng tâm; đồng thời tích hợp cơ chế duy trì ngữ cảnh, kiểm duyệt độ tin cậy 2 lớp và các tiện ích học tập phụ trợ nhằm cung cấp một công cụ học tập toàn diện, đáng tin cậy cho sinh viên.

1.2 Mục tiêu nghiên cứu

Mục tiêu cốt lõi của nghiên cứu là thiết kế, xây dựng và đánh giá hệ thống trợ lý học tập "AI Study Assistant". Các mục tiêu cụ thể được xác định như sau:

1. Xây dựng đường ống (pipeline) xử lý ngôn ngữ tự nhiên tiếng Việt, tích hợp kiến trúc RAG với cơ chế Trí nhớ lai (Hybrid Memory) để duy trì mạch ngữ cảnh hội thoại xuyên suốt, nhằm loại bỏ tình trạng ảo giác thông tin của mô hình tạo sinh [2], [16].
2. Đề xuất cải tiến thuật toán tóm tắt rút trích (Extractive Summarization) thông qua việc tích hợp trọng số cá nhân hóa dựa trên từ điển chuyên ngành (Domain Dictionary) của lĩnh vực HTTT.
3. Cài đặt cơ chế tóm tắt lai (Hybrid Summarization) tiên tiến, kết hợp giữa thuật toán rút trích để xác định câu chứa thông tin cốt lõi và LLM để tóm lược, làm mượt ngữ pháp.
4. Triển khai phương pháp kiểm duyệt độ tin cậy 2 lớp (Local Fact-Checking kết hợp LLM-as-a-Judge) để tự động đánh giá độ trung thực (Faithfulness) của các câu trả lời tạo sinh, qua đó cung cấp cơ sở đáng tin cậy cho người sử dụng [6], [17].
5. Xây dựng phần mềm trợ lý học tập hoàn chỉnh, trong đó tận dụng cấu trúc dữ liệu sinh ra từ thuật toán lỗi để tích hợp thêm các tiện ích học tập phụ trợ (Sơ đồ tư duy, Thẻ ôn tập) nhằm gia tăng giá trị ứng dụng thực tiễn [18], [19].

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu cốt lõi của đề tài tập trung vào việc khai phá các phương pháp và thuật toán nền tảng trong lĩnh vực Tóm tắt tự động văn bản (Automatic Text Summarization) [5]. Nhằm khắc phục những hạn chế của các phương pháp tóm tắt truyền thống, nghiên cứu tiến hành phân tích sâu vào Kiến trúc Sinh văn bản tăng cường truy xuất (Retrieval-Augmented Generation - RAG) để kết nối thông tin [2]. Bên cạnh đó, để tối ưu hóa quá trình lựa chọn ngữ cảnh, nền tảng toán học của các thuật toán phân tích đồ thị văn bản [1], [7] cũng được đặt làm trọng tâm nghiên cứu

và cải tiến trong hệ thống. Đồng thời, đối tượng nghiên cứu cũng mở rộng sang các kỹ thuật tối ưu hóa bộ nhớ ngữ cảnh và đo lường độ tin cậy văn bản tạo sinh.

1.3.2 Phạm vi dữ liệu

Phạm vi dữ liệu thực nghiệm của đề tài được giới hạn nghiêm ngặt trong vùng tri thức học thuật, tập trung xử lý các tài liệu gốc mang định dạng định dạng văn bản phổ biến như PDF và DOCX. Cụ thể, nội dung của các tài liệu này thuộc chuyên ngành Hệ thống Thông tin và Khoa học Máy tính nhằm đảm bảo tính chuyên biệt hóa của bộ từ vựng và từ điển chuyên ngành. Đồng thời, để đo lường và đối chiếu hiệu năng của thuật toán tóm tắt một cách khách quan trên một hệ quy chiếu chung, nghiên cứu sử dụng tập dữ liệu chuẩn hóa XLSum-Vietnamese [8] làm cơ sở tham chiếu (benchmark) trong các kịch bản đánh giá.

1.3.3 Phạm vi kỹ thuật

Về mặt công nghệ, đề tài giới hạn phạm vi triển khai trong một kiến trúc lai (hybrid) kết hợp giữa xử lý cục bộ và giao tiếp qua đám mây. Quá trình tiền xử lý ngôn ngữ tự nhiên đặc thù cho tiếng Việt, bao gồm việc tách từ và phân mảnh, được thực hiện hoàn toàn nội bộ bằng cách tích hợp thư viện NLP mã nguồn mở [15]. Các tiện ích học tập gia tăng (Sơ đồ tư duy, Thẻ ôn tập) được giới hạn xử lý cục bộ (local) nhằm tận dụng lại cấu trúc thuật toán đã có mà không phát sinh thêm chi phí giao tiếp API.

Đối với các tác vụ đòi hỏi khả năng suy luận bậc cao như phân tích ý định người dùng, tạo sinh văn bản mạch lạc và đánh giá chất lượng tự động, hệ thống tận dụng sức mạnh của mô hình ngôn ngữ lớn Gemini (cụ thể là phiên bản gemini-2.5-flash) thông qua giao thức API [4].

1.4 Đóng góp của đề tài

1.4.1 Về mặt khoa học và phương pháp luận

Đề xuất được một quy trình Tóm tắt lai (Hybrid Summarization) tích hợp hệ số chuyên ngành. Bên cạnh đó, đề tài đóng góp một giải pháp nâng cao độ tin cậy cho hệ thống RAG thông qua kiến trúc quản lý ngữ cảnh hội thoại linh hoạt và cơ chế kiểm duyệt nội dung 2 lớp, giúp giảm thiểu rủi ro "ảo giác" trong giáo dục.

1.4.2 Về mặt thực tiễn

Xây dựng thành công hệ thống phần mềm AI Study Assistant với giao diện trực quan. Ứng dụng cho phép sinh viên tương tác đa chiều (đọc song song, tra cứu chéo, tóm tắt tự động) cùng hệ thống cảnh báo sai lệch thông tin thời gian thực. Hơn thế nữa, phần mềm cung cấp các tiện ích học tập đính kèm như Bản đồ tư duy và Thẻ ôn tập (hỗ trợ xuất file Anki), mang lại một quy trình học tập khép kín và hiệu quả.

1.5 Bố cục của luận văn

Ngoài phần Mở đầu, Tóm tắt và Danh mục tài liệu tham khảo, nội dung chính của luận văn được tổ chức thành 4 chương tiếp theo như sau:

- Dựa trên luật (Rule-based / Regex): Sử dụng biểu thức chính quy (Pattern matching) để rà soát các từ khóa mệnh lệnh rõ ràng (như "tóm tắt", "so sánh"). Phương pháp này tốc độ cao, độ trễ bằng 0 và không tốn chi phí điện toán.
- Chương 2 - Cơ sở lý thuyết: Trình bày các kiến thức nền tảng về xử lý ngôn ngữ tự nhiên, các phương pháp tóm tắt văn bản, thuật toán phân tích đồ thị TextRank, kiến trúc truy xuất tăng cường RAG và các độ đo chuẩn mực dùng để đánh giá hệ thống tạo sinh.
- Chương 3 - Mô hình và phương pháp đề xuất: Mô tả chi tiết kiến trúc tổng thể của hệ thống AI Study Assistant; đề xuất đường ống tóm tắt lai (Hybrid Summarization); xây dựng kiến trúc Trí nhớ lai (Hybrid Memory) cho chatbot RAG; và cách thức tận dụng dữ liệu lỗi để xây dựng các tiện ích học tập trực quan.
- Chương 4 - Thực nghiệm và đánh giá kết quả: Trình bày chi tiết các kịch bản thực nghiệm trên tập dữ liệu chuẩn hóa XLSum và tập dữ liệu giáo trình chuyên ngành; đối chiếu hiệu năng của hệ thống với các mô hình tiên tiến hiện nay; và đánh giá độ trung thực của AI thông qua kỹ thuật LLM-as-a-Judge.
- Chương 5 - Kết luận và hướng phát triển: Đúc kết lại những thành tựu khoa học và thực tiễn mà đề tài đã đạt được, đồng thời nhìn nhận những hạn chế còn tồn đọng để đề xuất các hướng nâng cấp hệ thống trong tương lai.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về Tóm tắt tự động văn bản (Automatic Text Summarization)

Tóm tắt tự động văn bản là quá trình ứng dụng thuật toán để rút gọn độ dài của một văn bản trong khi vẫn bảo toàn được thông tin cốt lõi [5]. Dựa trên cơ chế tạo sinh đầu ra, bài toán này được phân thành hai hướng chính:

1. Tóm tắt rút trích (Extractive Summarization): Phân rã văn bản thành các câu, đánh giá trọng số và trích xuất nguyên văn các câu quan trọng nhất. Phương pháp này đảm bảo tính trung thực tuyệt đối nhưng có thể thiếu mạch lạc [5].
2. Tóm tắt tóm lược (Abstractive Summarization): Xây dựng biểu diễn ngữ nghĩa và dùng mô hình ngôn ngữ để sinh ra các câu hoàn toàn mới. Phương pháp này mạch lạc nhưng tiềm ẩn rủi ro sinh thông tin sai lệch [5].

Hệ thống trong đề tài áp dụng mô hình lai (Hybrid), dùng rút trích để "khóa" tri thức chuyên ngành, sau đó dùng mô hình tóm lược để tái cấu trúc văn bản.


Bảng 2.1: So sánh đặc trưng của hai phương pháp tóm tắt tự động.

Tiêu chí phân tích	Tóm tắt rút trích (Extractive Summarization)	Tóm tắt tóm lược (Abstractive Summarization)
Cơ chế hoạt động	Trích xuất nguyên văn các câu quan trọng nhất từ bản gốc.	Phân tích ngữ nghĩa và sinh ra câu mới hoàn toàn.
Độ chính xác / Trung thực	Tuyệt đối (Không thể sinh ra thông tin giả / Ảo giác).	Thấp hơn (Có nguy cơ cao sinh ra ảo giác thông tin).
Tính mạch lạc của mạch văn	Thường rời rạc, thiếu các từ nối chuyển ý giữa các câu.	Mượt mà, liền mạch, tự nhiên như con người viết.
Chi phí điện toán (Computing)	Thấp (Sử dụng thuật toán đồ thị, ma trận tần suất).	Rất cao (Đòi hỏi GPU để chạy Mô hình ngôn ngữ lớn).
Sự phù hợp với ngành HTTT	Tốt cho việc giữ nguyên định nghĩa, thuật ngữ khoa học.	Tốt cho việc giải thích, tổng hợp đa luồng tài liệu.

2.2 Từ điển chuyên ngành (Domain Dictionary) trong cấu trúc dữ liệu

Trong khoa học máy tính, Ontology không chỉ đơn thuần là một danh sách từ vựng (vocabulary list) mà là một cấu trúc biểu diễn tri thức chính thức của một lĩnh vực chuyên biệt [3]. Một Ontology cơ bản định nghĩa các Lớp (Classes), Thuộc tính (Attributes) và Mối quan hệ (Relations) giữa các thực thể. Việc tích hợp từ điển chuyên ngành (Domain Dictionary) vào Xử lý Ngôn ngữ Tự nhiên (NLP) giúp hệ thống vượt qua giới hạn của việc so khớp chuỗi thông thường để tiến tới hiểu ngữ nghĩa miền (Domain-specific semantics) [3]. Trong bối cảnh ngành Hệ thống Thông tin (HTTT), Từ điển chuyên ngành đóng vai trò như một bộ lọc, giúp các thuật toán

học máy phân biệt được đâu là thuật ngữ khoa học cốt lõi cần được bảo toàn, đâu là từ ngữ chuyển ý thông thường.




Hình 2.1: Mô hình biểu diễn từ điển chuyên ngành (Domain Dictionary) ứng dụng trong chuyên ngành HTTT.

2.3 Thuật toán đồ thị TextRank và Topic-Sensitive PageRank

Thuật toán TextRank là một phương pháp không giám sát dựa trên đồ thị, được tinh chỉnh từ thuật toán PageRank [7]. Điểm số của một đỉnh V_i (đại diện cho một câu) được tính qua nhiều vòng lặp theo công thức:

$$WS(V_i) = (1 - d) + d \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j)$$

Trong cấu trúc đồ thị truyền thống, vector xác suất ban đầu $(1 - d)/N$ được phân phối đều. Tuy nhiên, theo lý thuyết của Topic-Sensitive PageRank [1], luồng phân phối này có thể được "thiên vị" (bias) bằng một vector cá nhân hóa (personalization vector) $\vec{p}$. Kết hợp với nền tảng từ điển chuyên ngành (Domain Dictionary) đã định nghĩa ở mục 2.2, các đỉnh chứa thực thể thuộc Dictionary sẽ được cập nhật một tham số gia tăng (base_bonus), buộc đồ thị hội tụ điểm số về các câu chứa tri thức chuyên ngành [3], [1].



Hình 2.2: Sơ đồ cải tiến TextRank với trọng số cá nhân hóa.

Bên cạnh chức năng tính toán trọng số để trích xuất câu, bản thân ma trận kề (adjacency matrix) sinh ra từ thuật toán TextRank chứa đựng toàn bộ thông tin về cấu trúc liên kết ngữ nghĩa của tài liệu [18]. Thay vì chỉ sử dụng kết quả đầu ra, các nghiên cứu về Trực quan hóa Tri thức (Knowledge Visualization) cho thấy việc tái sử dụng (cache) trực tiếp đồ thị toán học này để chuyển đổi thành Sơ đồ tư duy (Concept Map/Mindmap) mang lại hai lợi ích lớn: (1) Mô phỏng chính xác luồng suy luận của thuật toán, và (2) Tiết kiệm hoàn toàn tài nguyên điện toán so với việc sử dụng các mô hình tạo sinh để vẽ lại đồ thị từ đầu (Zero-Token Computing) [18].

2.4 Kiến trúc Retrieval-Augmented Generation (RAG) và Quản lý ngữ cảnh

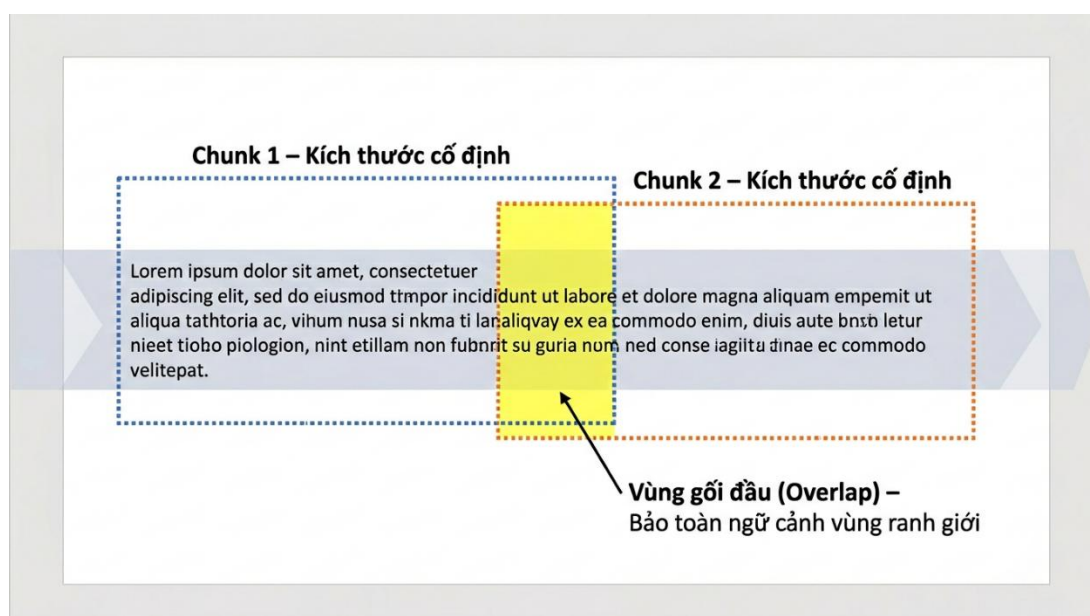
Kiến trúc RAG được đề xuất nhằm khắc phục rủi ro "ảo giác thông tin" của LLMs bằng cách truy xuất dữ liệu từ không gian ngoại vi trước khi tạo sinh [2].

2.4.1 Truy xuất thưa (Sparse Retrieval) vs Truy xuất đặc (Dense Retrieval)

Trong kiến trúc Sinh văn bản tăng cường truy xuất (RAG), module Truy xuất (Retriever) đóng vai trò then chốt nhằm tìm kiếm ngữ cảnh phù hợp và thường được chia thành hai trường phái tiếp cận chính: Truy xuất đặc (Dense Retrieval) và Truy xuất thưa (Sparse Retrieval) [10]: Phương pháp Truy xuất đặc ứng dụng sức mạnh của các mạng nơ-ron học sâu để mã hóa (embed) câu truy vấn và văn bản thành các vector ngữ nghĩa (semantic vectors) trong không gian liên tục nhiều chiều, sau đó lưu

trữ và đối sánh tại các cơ sở dữ liệu vector chuyên dụng (Vector Database). Ngược lại, phương pháp Truy xuất thừa tận dụng các kỹ thuật biểu diễn từ vựng rời rạc truyền thống như TF-IDF (Term Frequency-Inverse Document Frequency) hoặc thuật toán BM25. Đặc trưng của kỹ thuật này là cấu trúc không gian vector được xây dựng trực tiếp dựa trên tần suất xuất hiện và mức độ hiếm gặp thực tế của từ vựng trong toàn bộ tập tài liệu, thay vì cố gắng mô hình hóa các mối quan hệ ngữ nghĩa tiềm ẩn.

Mặc dù Truy xuất đặc đang là xu hướng phổ biến nhờ khả năng nắm bắt ngữ cảnh tốt, việc áp dụng phương pháp này vào môi trường tài liệu giáo trình kỹ thuật lại bộc lộ một số sự thiếu tương thích. Trong miền dữ liệu chuyên ngành như Hệ thống Thông tin, các thuật ngữ khoa học (ví dụ: cơ sở dữ liệu quan hệ, bộ định tuyến) thường mang tính định danh độc nhất và yêu cầu khả năng khớp từ vựng chính xác tuyệt đối (exact keyword matching) thay vì tìm kiếm các từ đồng nghĩa tương đương. Dựa trên đặc thù này, nghiên cứu quyết định lựa chọn kỹ thuật mã hóa vector TF-IDF kết hợp cùng độ đo khoảng cách Cosine (Cosine Similarity) thuộc trường phái Truy xuất thừa làm cơ chế cốt lõi cho phân hệ RAG. Sự lựa chọn này không chỉ đảm bảo tỷ lệ bắt trúng chính xác các từ khóa chuyên môn mà còn được chứng minh là một giải pháp tối ưu hóa tài nguyên phần cứng, giúp tiết kiệm đáng kể chi phí và thời gian tính toán cho hệ thống.




Hình 2.3: Kỹ thuật phân mảnh văn bản trượt (Sliding Window Chunking)

2.4.2 Kiến trúc Trí nhớ Lai (Hybrid Memory) trong đối thoại

Đối với các hệ thống tương tác liên tục, LLM mặc định không có khả năng ghi nhớ bối cảnh (stateless). Theo các chiến lược quản lý bộ nhớ tiên tiến [10], [16], việc nạp toàn bộ lịch sử trò chuyện sẽ dẫn đến hiện tượng tràn bộ nhớ token và làm loãng ngữ cảnh. Do đó, hệ thống áp dụng kiến trúc Trí nhớ Lai (Hybrid Memory) kết hợp hai cơ chế:

1. Trí nhớ tức thời (Sliding Window Memory): Giữ lại một số lượng nhỏ (ví dụ: 2 lượt) các câu hỏi - đáp án gần nhất để giải quyết các truy vấn sử dụng đại từ chỉ định (như "tại sao lại như vậy?").
2. Trí nhớ dài hạn (Vector-based Memory): Mã hóa toàn bộ lịch sử hội thoại cũ thành các vector TF-IDF. Khi có truy vấn mới, hệ thống tính toán khoảng cách Cosine để tự động truy xuất lại những đoạn hội thoại trong quá khứ có liên quan nhất đến ngữ cảnh hiện tại [16]. Kỹ thuật này giúp hệ thống duy trì mạch logic xuyên suốt toàn bộ phiên làm việc mà vẫn tối ưu hóa chi phí API.



Hình 2.4: Lưu đồ Trí nhớ Lai

2.4.3 Cơ chế sinh câu hỏi tự động (AQG) và Thẻ ghi nhớ (Flashcard)


Sinh câu hỏi tự động (Automated Question Generation - AQG) là quá trình ứng dụng NLP để tạo ra các bài kiểm tra từ văn bản gốc nhằm hỗ trợ học tập chủ động [19]. Một trong những hình thức phổ biến nhất là bài tập điền khuyết (Cloze Deletion/Flashcard). Thay vì sử dụng LLM để tạo câu hỏi (dễ phát sinh lỗi logic và tốn kém), phương pháp AQG dựa trên luật (Rule-based AQG) kết hợp với Từ điển chuyên ngành (Domain Ontology) mang lại độ chính xác tuyệt đối. Hệ thống sẽ quét các câu văn có độ quan trọng cao (dựa trên điểm TextRank) và sử dụng kỹ thuật Biểu thức chính quy (Regular Expressions) để "đọc lỗ" các thuật ngữ chuyên ngành [19]. Phương pháp này giúp tạo ra các bộ thẻ ôn tập tập trung vào trọng tâm kiến thức mà không tiêu tốn tài nguyên mô hình ngôn ngữ lớn.

2.5 Kỹ thuật Điều khiển Mô hình Ngôn ngữ trong hệ thống đối thoại

2.5.1 Nhận diện ý định (Intent Recognition)

Hệ thống hội thoại hiện đại ứng dụng cơ chế lai (Hybrid Intent Recognition) nhằm cân bằng giữa tốc độ và độ chính xác, quy trình xử lý được mô tả tại Hình 2.5:

- Tầng xử lý Cục bộ (Rule-based / Pattern Matching): Sử dụng các biểu thức so khớp chuỗi trên tập quy tắc INTENT_PATTERNS. Phương pháp này ưu tiên xử lý các lệnh phổ biến (như tóm tắt, định nghĩa), cho kết quả tức thời với chi phí điện toán bằng 0.
- Tầng xử lý Trí tuệ nhân tạo (Zero-shot Classification): Chỉ khi tầng cục bộ không xác định được mục đích, hệ thống mới kích hoạt Mô hình Ngôn ngữ Lớn Gemini. Nhờ năng lực Zero-shot, LLM có thể phân loại các câu hỏi phức tạp hoặc có cách diễn đạt lạ mà không cần được huấn luyện lại, đảm bảo hệ thống luôn phản hồi đúng trọng tâm [16].



Hình 2.5: Sơ đồ cơ chế nhận diện ý định lai (Hybrid Intent Recognition) trong hệ thống đối thoại.

2.5.2 Kỹ thuật thiết kế chỉ thị (Prompt Engineering)

Prompt Engineering là quá trình cấu trúc văn bản đầu vào để giao tiếp và điều khiển hành vi của LLM [1]. Để khắc phục tính ngẫu nhiên của mô hình tạo sinh, kỹ thuật Thiết kế chỉ thị ràng buộc (Constrained Generation Prompting) được áp dụng. Kỹ thuật này thiết lập các rào cản từ vựng, cấm mô hình suy diễn ngoài tập dữ liệu (Context) được cung cấp, ép buộc hệ thống hoạt động như một công cụ tổng hợp thay vì một cỗ máy sáng tạo văn bản [10].

2.6 Mô hình Ngôn ngữ Lớn (LLMs) và Kiến trúc Gemini

Hãy hình dung các Mô hình Ngôn ngữ Lớn (LLMs) như một "nhà thông thái nhưng hay mơ mộng". Họ sở hữu vốn từ vựng phong phú và khả năng diễn đạt tuyệt vời, nhưng lại dễ dàng chìm đắm vào sự tưởng tượng và bịa ra những thông tin có vẻ thuyết phục nhưng không có thật (ảo giác). Dòng mô hình Gemini (gemini-2.5-flash) là một "nhà thông thái" ưu tú thuộc hệ thống nền tảng đa phương thức tiên tiến, sở hữu năng lực suy luận phức tạp trong các ngữ cảnh dài [1]. Tuy nhiên, để biến nhà thông thái này thành một chuyên gia đáng tin cậy trong môi trường học thuật, hệ thống cần một cơ chế ràng buộc. Nhờ khả năng tuân thủ nghiêm ngặt các chỉ thị từ Prompt Engineering, mô hình này đáp ứng hoàn hảo vai trò cốt lõi trong khâu làm mượt văn bản (Abstractive Polish) và phân loại đối thoại, miễn là nó được cung cấp một "mỏ neo" tri thức vững chắc.

2.7 Các độ đo đánh giá Hệ thống (Evaluation Metrics)

Đánh giá chất lượng của một hệ thống lai đòi hỏi các thước đo từ vựng (cho tóm tắt) và các thước đo ngữ nghĩa (cho RAG) [11].

2.7.1 Các độ đo từ vựng học (ROUGE & BLEU)

ROUGE (Recall-Oriented Understudy for Gisting Evaluation): Đo lường độ phủ của N-gram giữa bản sinh ra và bản tham chiếu [12]. ROUGE-1 và ROUGE-2 tập trung vào mức độ trùng lặp từ vựng, trong khi ROUGE-L (Longest Common Subsequence) phản ánh cấu trúc liên kết của chuỗi.

BLEU (BiLingual Evaluation Understudy): Tập trung vào tỷ lệ chính xác (Precision) của các N-gram sinh ra và áp dụng hình phạt nếu văn bản sinh ra quá ngắn [13].

2.7.2 RAG Kiểm duyệt độ tin cậy và Đánh giá LLM-as-a-Judge

Trong hệ thống Kiến trúc sinh văn bản tăng cường truy xuất (RAG), ROUGE và BLEU không đủ năng lực phát hiện các lỗi sai về mặt logic hay hiện tượng ảo giác (Hallucination) [2], [11]. Để đảm bảo tính trung thực (Faithfulness), các hệ thống hiện đại áp dụng cơ chế kiểm duyệt nhiều lớp [17]:

- Kiểm duyệt Cục bộ (Local Fact-Checking): Trích xuất các mệnh đề (claims) và đối chiếu trực tiếp với văn bản nguồn thông qua thuật toán đo lường tương đồng ký tự (Char N-gram TF-IDF). Phương pháp này giúp phát hiện nhanh các câu văn thiếu minh chứng hoặc trích dẫn sai nguồn mà không cần dùng đến LLM.
- LLM-as-a-Judge: Kế thừa khung đánh giá RAGAS (RAG Assessment) [17], luận văn ứng dụng cơ chế dùng LLM làm giám khảo [6] cho bước kiểm duyệt chuyên sâu. Bằng kỹ thuật tư duy theo chuỗi (Chain-of-Thought), một LLM độc lập sẽ đối chiếu "Câu trả lời của hệ thống" với "Ngữ cảnh được truy xuất" để chấm điểm hoặc đưa ra phán quyết cuối cùng (PASS/FAIL). Thang đo này xác định xem toàn bộ các phát biểu trong câu trả lời có thể được suy ra từ ngữ cảnh gốc hay không, qua đó ngăn chặn rủi ro sai lệch kiến thức trong môi trường giáo dục [6], [11].

CHƯƠNG 3 PHƯƠNG PHÁP VÀ MÔ HÌNH ĐỀ XUẤT

3.1 Kiến trúc tổng quát và Luồng dữ liệu hệ thống

Hệ thống AI Study Assistant được thiết kế theo kiến trúc module hóa với 3 lớp xử lý (Layer) tuần tự. Điểm nhấn của kiến trúc không chỉ nằm ở các thuật toán lõi, mà ở cơ chế "Mỏ neo tri thức an toàn": kiến trúc RAG đóng vai trò là chiếc mỏ neo buộc "nhà thông thái" LLM phải neo đậu, chỉ được phép trả lời dựa trên những trang giáo trình có thật.

Luồng dữ liệu của hệ thống có thể được trực quan hóa như một hiệu ứng trượt (slide) thông minh, định tuyến dữ liệu qua 3 lớp xử lý như sau:

Lớp 1: Lớp Đầu Vào (Input Layer), giai đoạn này chịu trách nhiệm tiếp nhận và tiền xử lý dữ liệu thô từ người dùng.

Hệ thống hỗ trợ đa dạng các định dạng tài liệu học tập phổ biến như PDF, Word (DOCX) và văn bản thuần túy (TXT).

Module Tiền xử lý (Tokenization & Chunking) sẽ làm sạch văn bản, chia nhỏ thành các đoạn (chunks) có phần gói đầu, và thực hiện tách từ tiếng Việt bằng thư viện Underthesea.

[Luồng dữ liệu trung gian]: Đầu ra của lớp này được chuẩn hóa thành một cấu trúc đối tượng trung gian (JSON-like Schema) lưu trữ tạm thời trong bộ nhớ, có định dạng: `DocumentObject = {doc_id, raw_text, chunks[], tfidf_matrix}`. Việc đóng gói dữ liệu này đảm bảo thông tin phân mảnh và ma trận toán học được tính toán duy nhất một lần, sẵn sàng phân phối cho Lớp 2.

Lớp 2: Lớp Xử Lý Lõi (Core Processing Layer), đây là trung tâm tính toán tiếp nhận luồng JSON Object từ Lớp 1. Tại đây, câu hỏi của người dùng sẽ gặp một "nút chuyển hướng" (Router) và được định tuyến (routing) trượt vào một trong hai đường ống chuyên biệt dựa trên ý định:


- Luồng trượt thứ nhất (Luồng Tóm tắt lại - Hybrid Summarization): Khi ý định là yêu cầu tóm tắt, dữ liệu trượt thẳng vào thuật toán đồ thị TextRank. Tại đây, thuật toán bị can thiệp bởi Từ điển chuyên ngành (Domain Dictionary), nơi các câu chứa thuật ngữ IT được cộng điểm thưởng + base_bonus. Đầu ra của luồng trượt này là gói dữ liệu [Top N Câu Trích Xuất] mang đậm tính hàn lâm.
- Luồng trượt thứ hai (Luồng RAG & Hỏi đáp): Khi ý định là câu hỏi truy vấn, dữ liệu được trượt xuống luồng RAG – nơi kích hoạt chiếc "Mỏ neo tri thức". Cơ chế Định tuyến Ý định Đa tầng (Regex kết hợp LLM) phân tích yêu cầu, dùng thuật toán TF-IDF Retriever quét ma trận vector để tìm đáp án. Đồng thời, kiến trúc Trí nhớ Lai (Hybrid Memory) được kích hoạt, kết hợp lưu trữ

2 lượt hội thoại gần nhất và truy xuất tự động các hội thoại cũ. Đầu ra của luồng này là gói thông tin toàn diện: [Ngữ cảnh (Mở neo) + Lịch sử + Câu hỏi].

Lớp 3: Lớp Tạo Sinh & Đánh Giá (Generation & Evaluation Layer), lớp này giao tiếp trực tiếp với Mô hình Ngôn ngữ Lớn (Gemini LLM) để sinh ra sản phẩm cuối cùng và tự kiểm duyệt chất lượng:

Tạo sinh nội dung: Mô hình Gemini tiếp nhận 1 trong 2 gói dữ liệu từ Lớp 2 ([Top N Câu Trích Xuất] hoặc [Ngữ cảnh + Lịch sử + Câu hỏi]). Bằng khả năng hiểu ngôn ngữ (NLU), LLM đóng vai trò tổng hợp, làm mượt ngữ pháp và sinh ra "Bản tóm tắt" hoặc "Câu trả lời" mạch lạc trả về cho người dùng.

Đánh giá tự động (Luồng Evaluator): Từ câu trả lời vừa sinh ra, hệ thống thiết lập một luồng phản hồi ngược (feedback loop) đi vào module LLM-as-a-Judge. Khối giám khảo này có nhiệm vụ đối chiếu chéo giữa Câu trả lời và Ngữ cảnh gốc, từ đó xuất ra đồng hồ đo [Điểm Faithfulness: 1-5] nhằm cảnh báo người dùng về mức độ Ảo giác (Hallucination) của AI.



Hình 3.1 Sơ đồ kiến trúc tổng thể và luồng dữ liệu trung gian của hệ thống AI Study Assistant.

3.2 Kỹ thuật Tiền xử lý dữ liệu và Vector hóa

Trước khi đưa vào các thuật toán trích xuất hay mô hình ngôn ngữ, văn bản thô (raw text) cần được chuẩn hóa để đảm bảo máy tính có thể hiểu được đặc trưng ngữ nghĩa.

3.2.1 Phân tách từ vựng tiếng Việt (Tokenization)

Từ vựng tiếng Việt có thể bao gồm nhiều âm tiết, do đó khoảng trắng không phải là ranh giới từ duy nhất. Để giải quyết rào cản này, hệ thống tích hợp thư viện mã nguồn mở Underthesea để tiến hành phân tách từ (Word Segmentation) [15]. Quá trình này đảm bảo các thuật ngữ chuyên ngành phức tạp (ví dụ: cơ_sở_dữ_liệu, hệ_quản_trị) được giữ nguyên vẹn thành một token duy nhất, đóng vai trò quyết định để thuật toán tính toán chính xác tần suất xuất hiện của từ (TF).

3.2.2 Phân mảnh văn bản trượt gối đầu (Sliding Window Chunking)

Để phục vụ cho quá trình đối chiếu vector cục bộ, tài liệu được phân rã thành các khối nhỏ (chunks). Kế thừa các phương pháp tối ưu hóa dữ liệu đầu vào [10], hệ thống áp dụng cơ chế cửa sổ trượt (sliding window) với cấu hình tham số: kích thước đoạn (chunk_size) là 150 từ và độ gối đầu (chunk_overlap) là 30 từ.

Việc lựa chọn các tham số này được thiết lập dựa trên đặc thù ngữ nghĩa của ngành Hệ thống Thông tin. Trung bình một đoạn văn định nghĩa một khái niệm kỹ thuật tiếng Việt tiêu tốn từ 100 đến 150 từ. Do đó, chunk_size = 150 đảm bảo bao trọn một khối ngữ cảnh độc lập. Đồng thời, chunk_overlap = 30 (tương đương 20% độ dài) là khoảng đệm an toàn để các định nghĩa phức tạp nằm vắt ngang biên giới giữa hai khối văn bản không bị cắt xén, bảo toàn tính liên tục của tri thức.

3.3 Đề xuất Thuật toán Tóm tắt lại (Hybrid Summarization) kết hợp tập từ vựng chuyên ngành

Các phương pháp tóm tắt rút trích truyền thống (Extractive) đánh giá tầm quan trọng của câu hoàn toàn dựa trên cấu trúc đồ thị ngôn ngữ chung, dẫn đến rủi ro bỏ sót các định nghĩa chuyên ngành nếu chúng nằm ở các câu ngắn hoặc ít liên kết [5], [7]. Nhằm khắc phục hạn chế này, nghiên cứu đề xuất một đường ống Tóm tắt lại (Hybrid Summarization) tích hợp tập từ vựng chuyên ngành.

3.3.1 Cá nhân hóa đồ thị văn bản dựa trên từ điển chuyên ngành (Domain-driven Personalization)

Quy trình xây dựng và biểu diễn Từ điển chuyên ngành (Dictionary Construction): Bộ từ điển chuyên ngành (Domain Dictionary) trong hệ thống không chỉ là một danh sách phẳng (flat list) mà là kết quả của một quy trình thanh lọc kỹ lưỡng. Dữ liệu đầu vào được khai thác từ hai nguồn chính xác: (1) Đề cương chi tiết (Syllabus) của các môn học cốt lõi ngành Hệ thống Thông tin và (2) Bộ tiêu chuẩn thuật ngữ Công nghệ Thông tin. Các thuật ngữ sau khi thu thập được đưa qua mô hình ngôn ngữ lớn (đóng vai trò là AI Agent) để sàng lọc, loại bỏ các từ đồng âm khác nghĩa và chuẩn hóa thành chữ thường.

Ràng buộc về khái niệm: Cần làm rõ rằng, trong phạm vi triển khai của ứng dụng ở giai đoạn này, khái niệm từ điển chuyên ngành (Domain Dictionary) đang

được đơn giản hóa (simplified) dưới dạng một "Tập từ vựng chuyên ngành" (Domain Terminology Set) sử dụng cấu trúc set(). Việc xây dựng một Đồ thị tri thức (Knowledge Graph) hoàn chỉnh có chứa các "mối quan hệ ngữ nghĩa" (Relations) phức tạp giữa các thực thể là một bài toán lớn, sẽ được đề xuất như một hướng phát triển chuyên sâu trong tương lai.

Về mặt cấu trúc dữ liệu, thay vì lưu trữ dạng mảng (Array) thông thường, bộ từ điển này được khởi tạo vào bộ nhớ dưới dạng cấu trúc Bảng băm (Hash Set) set(). Cấu trúc này cho phép thời gian tra cứu sự tồn tại của từ khóa đạt độ phức tạp $O(1)$, tối ưu hóa tốc độ xử lý khi đối chiếu với các văn bản dài.


Cơ sở toán học của sự cá nhân hóa đồ thị:

Dựa trên cơ sở toán học của thuật toán phân tích đồ thị có chủ đích [1], hệ thống đề xuất một kỹ thuật hoàn toàn mới: Cá nhân hóa đồ thị văn bản dựa trên từ điển chuyên ngành. Trong thuật toán TextRank thông thường, vector khởi tạo xác suất cho các đỉnh được phân phối đều, khiến các câu chứa tri thức chuyên ngành có thể bị chìm ngấm nếu chúng ngắn hoặc ít liên kết.

Để khắc phục, hệ thống tiến hành quét từng đỉnh V_i . Nếu đỉnh này chứa thực thể trùng khớp với Bảng băm từ khóa chuyên ngành, thành phần thứ i trong vector cá nhân hóa ($\vec{p}$) sẽ được điều chỉnh tăng cường theo công thức:

$$p_i = p_{initial} + (Count(ontology_terms \in V_i) \times base_bonus)$$

Trong đó, tham số $base_bonus = 1.0$ đóng vai trò như một hằng số lực hấp dẫn. Hãy hình dung bộ từ điển chuyên ngành là một "Thời nam châm thuật ngữ" không lồ được thả vào không gian đồ thị. Tham số $base_bonus = 1.0$ chính là lực từ trường do thời nam châm này phát ra, tạo ra một lực hấp dẫn toán học buộc thuật toán TextRank phải "hút" dòng chảy xác suất của chuỗi Markov dồn về phía các đỉnh chứa thuật ngữ IT quan trọng. Sự can thiệp này không còn là sự ngẫu nhiên phân phối đều, mà là một sự "bẻ lái" (bias) có chủ đích: các câu mang tri thức hàn lâm trở thành các tâm trọng lực, ép hệ thống phải hội tụ điểm số cao nhất về phía chúng để ưu tiên trích xuất.



Hình 3.2: Lưu đồ thuật toán thể hiện sự can thiệp của lực từ trường *base_bonus* vào chuỗi Markov để hút các từ khóa chuyên ngành.

Quy trình thanh lọc từ vựng khách quan (AI Agent Filtering): Để đảm bảo tính khách quan và tránh định kiến cá nhân (human bias) trong việc chọn lọc từ khóa, hệ thống ứng dụng AI Agent vào quy trình xử lý thô. Thay vì nhặt từ thủ công, toàn bộ nội dung Đề cương chi tiết (Syllabus) được đưa qua prompt của LLM với chỉ thị zero-shot: "Trích xuất các danh từ/cụm danh từ là khái niệm kỹ thuật cốt lõi, loại bỏ các động từ hành động và từ nối". Quá trình này giúp định lượng hóa các thuật ngữ, loại bỏ các từ đồng âm dị nghĩa (ambiguity) và tự động chuẩn hóa (lower-casing, lemmatization) trước khi băm vào cấu trúc Hash Set.

1. Thành phần của đồ thị văn bản

Các đỉnh (V_1, V_2, V_3, V_4, V_5): Mỗi đỉnh (Node) trong đồ thị đại diện cho một câu hoặc một phân đoạn văn bản (chunk) được bóc tách từ tài liệu gốc.

Các cạnh và trọng số: Các đường nối giữa các đỉnh biểu diễn mối quan hệ ngữ nghĩa giữa các câu (thường được tính bằng độ đo Cosine Similarity trên không gian vector TF-IDF). Các con số trên cạnh (như 0.12, 0.45, 0.74...) chính là trọng số tương đồng. Mối liên kết càng mạnh, trọng số càng cao.

2. Sự can thiệp của Từ điển chuyên ngành (Domain Dictionary) và tham số *base_bonus*

Thay vì sử dụng vector khởi tạo phân phối đều cho tất cả các câu như TextRank truyền thống, hệ thống tiến hành đối chiếu từng đỉnh với Từ điển chuyên ngành.

Các đỉnh nổi bật (V_2 và V_4): Trực quan hóa cho việc hệ thống phát hiện ra câu V_2 và V_4 có chứa các thuật ngữ chuyên ngành khớp với bộ từ điển. Lúc này, hệ thống áp dụng phép cộng tham số `base_bonus` để tăng cường trọng số cho các đỉnh này trong vector cá nhân hóa.

3. Cơ chế hội tụ và Đầu ra

Việc bơm thêm `base_bonus` vào V_2 và V_4 đóng vai trò như một lực hấp dẫn toán học, can thiệp vào chuỗi Markov của đồ thị. Khi thuật toán PageRank/TextRank chạy vòng lặp để hội tụ, dòng chảy xác suất sẽ có xu hướng "thiên vị", đổ dồn điểm số về phía các đỉnh màu đỏ và những đỉnh có liên kết mạnh với chúng.


So sánh đối chứng (Minh họa qua Hình 3.2):

Hình 3.2 chính là bức tranh trực quan hóa cho sự khác biệt mang tính bước ngoặt của thuật toán Lai. Qua hình ảnh dòng chảy xác suất đổ dồn về các đỉnh V_2 và V_4 , chúng ta có thể thấy rõ sự đối chứng:

- Nếu chỉ dùng TextRank thông thường, chúng ta có một bản tóm tắt thô cứng, rập khuôn theo tần suất từ vựng phổ thông và dễ bỏ sót các định nghĩa lõi.
- Nếu chỉ dùng AI sinh văn bản đơn thuần, hệ thống luôn trong trạng thái lo sợ về "ảo giác" (hallucination) – nơi máy tính tự bịa đặt thông tin không có trong giáo trình.

Nhờ phương pháp Lai, "lực hấp dẫn thuật ngữ" đã giữ chặt bản tóm tắt vào chân lý chuyên ngành. Kết hợp với kỹ thuật điều khiển câu lệnh (Prompt Engineering) khéo, hệ thống tạo ra bản tóm tắt vừa mạch lạc về mặt ngôn ngữ tự nhiên, vừa đảm bảo chính xác thuật ngữ chuyên môn. Đây chính là sự kết tinh giữa tri thức chuyên gia và sức mạnh tính toán đồ thị thuần túy.

Hiện thực hóa bằng thuật toán lập trình: Để chuyển đổi cơ sở toán học tuyến tính nêu trên thành mã nguồn thực thi trong hệ thống phần mềm, quy trình được mô hình hóa thành một lưu đồ thuật toán chi tiết tại Hình 3.3. Thuật toán sẽ duyệt qua vòng lặp của N đỉnh, thực hiện đối chiếu tập từ vựng thông qua cấu trúc Bảng băm (Hash Set) để tối ưu hóa thời gian chạy với độ phức tạp $\mathcal{O}(1)$. Các đỉnh thỏa mãn điều kiện sẽ được cộng tích lũy `base_bonus`, sau đó toàn bộ vector cá nhân hóa được chuẩn hóa (normalize) trước khi nạp vào thuật toán PageRank để hội tụ kết quả.



Hình 3.3: Biểu đồ hoạt động (Activity Diagram) minh họa "Mở neo tri thức" RAG và cơ chế Trí nhớ Lai (Hybrid Memory).

3.3.2 Kỹ thuật Prompt Engineering để làm mượt văn bản

Tập hợp các câu được trích xuất từ TextRank mang tính rời rạc và thiếu cấu trúc liên kết [5]. Các câu này được đóng gói và đưa vào mô hình ngôn ngữ lớn (Gemini) thông qua kỹ thuật thiết kế chỉ thị hệ thống (System Prompt Engineering) [1]. Để ngăn chặn LLM sáng tạo thêm thông tin, prompt được thiết kế với các quy tắc ràng buộc nghiêm ngặt như sau:

hung cấu trúc Prompt hệ thống áp dụng trong module tóm tắt:

"Hành động với tư cách là một chuyên gia Hệ thống thông tin. Nhiệm vụ của bạn là viết lại các câu dưới đây thành một đoạn văn tóm tắt mạch lạc. QUY TẮC RÀNG BUỘC TUYỆT ĐỐI:


1. CHỈ sử dụng thông tin được cung cấp trong văn bản nguồn.
2. KHÔNG ĐƯỢC bịa đặt, suy diễn hoặc thêm bất kỳ kiến thức bên ngoài nào.
3. Giữ nguyên các thuật ngữ chuyên ngành tiếng Việt/tiếng Anh. [Văn bản nguồn: {extracted_sentences}]"

Cơ chế kiểm soát khắt khe này giúp hệ thống kết hợp được sự mạch lạc của phương pháp tóm lược (Abstractive) và sự trung thực tuyệt đối của phương pháp rút trích (Extractive) [1].

3.4 Xây dựng Pipeline Kiến trúc sinh văn bản tăng cường truy xuất (RAG)

Song song với tính năng tóm tắt tài liệu tự động, module hội thoại đóng vai trò là một trợ lý ảo cho phép sinh viên đặt câu hỏi và tương tác trực tiếp với nội dung của cuốn giáo trình. Như đã đề cập, LLM là một "nhà thông thái hay mơ mộng", dễ sinh ra nội dung không có thật (ảo giác) nếu tự do diễn giải. Để giải quyết triệt để vấn đề này, quy trình hỏi đáp được vận hành dựa trên kiến trúc RAG – giải pháp tạo ra một "Chiếc mỏ neo tri thức". Thay vì để LLM tự do suy luận từ trí nhớ mờ nhạt của nó, kiến trúc RAG buộc mô hình phải truy xuất các đoạn văn bản thật từ giáo trình (ngữ cảnh) làm "mỏ neo", chỉ sinh ra câu trả lời nằm trong giới hạn của chiếc mỏ neo này. Kết hợp với cơ chế định tuyến (Routing) thông minh, hệ thống tối ưu hóa được cả tính chính xác lẫn hiệu năng tài nguyên.

Bộ định tuyến ý định sử dụng Regex được thiết kế bằng các luật bắt từ khóa mệnh lệnh (ví dụ: $\wedge$ (tóm tắt|tổng hợp|rút gọn)). Mặc dù giải pháp này giúp tối ưu hóa triệt để độ trễ (giảm từ 5.30s xuống 3.55s), nó bộc lộ hạn chế về tỷ lệ bỏ sót (False Negative) khi người dùng nhập câu lệnh phức tạp hoặc dùng tiếng lóng. Đây là sự đánh đổi có chủ đích giữa tính năng linh hoạt và hiệu năng phần cứng.



Hình 3.4: Biểu đồ hoạt động chi tiết luồng định tuyến và Kiến trúc sinh văn bản tăng cường truy xuất (RAG) của hệ thống.

Biểu đồ hoạt động (Activity Diagram) trong Hình 3.4 thể hiện chi tiết luồng dữ liệu trung gian và các bước xử lý nối tiếp nhau nhằm tạo ra câu trả lời chính xác, được chia thành 4 giai đoạn cốt lõi:

Giai đoạn 1: Nhập liệu và Định tuyến (Input & Routing)

Quá trình bắt đầu khi hệ thống tiếp nhận truy vấn (User Query) từ giao diện người dùng. Thay vì đưa câu hỏi ngay lập tức vào tìm kiếm, hệ thống triển khai một "nút chuyển hướng" thông qua module Nhận diện Ý định (Intent Recognition). Tùy thuộc vào phân tích cú pháp và ngữ nghĩa, luồng dữ liệu sẽ được trượt định tuyến vào nhánh xử lý tối ưu nhất:

- Nếu ý định được phân loại là yêu cầu "Tóm tắt", cửa nhánh RAG sẽ đóng lại và luồng dữ liệu được trượt trực tiếp sang Module Tóm tắt lại (Hybrid Summarization), kết thúc quá trình ở pipeline này.
- Ngược lại, nếu ý định được xác định là "Hỏi đáp", cửa nhánh RAG sẽ mở ra, cho phép luồng dữ liệu trượt tiếp xuống các giai đoạn truy xuất và tạo sinh bên dưới. Thiết kế định tuyến hai nhánh này giúp phân ranh giới rõ ràng và tiết kiệm tài nguyên điện toán.

Giai đoạn 2: Khớp nối và Truy xuất (Retrieval)

Đây là giai đoạn tìm kiếm thông tin nền tảng để phục vụ cho câu hỏi. Trước tiên, câu hỏi thô được vector hóa thành một biểu diễn toán học có kích thước $1 \times N$. Tiếp theo, thay vì phải chạy lại các thuật toán tính toán đắt đỏ, vector câu hỏi này sẽ được nhân trực tiếp với ma trận TF-IDF của tài liệu vốn đã được tạo sẵn và lưu trữ trong Bộ nhớ Cache RAM từ khâu Tiền xử lý. Việc tái sử dụng (reuse) dữ liệu này giúp hệ thống đo lường độ tương đồng Cosine (Cosine Similarity) với tốc độ gần như tức thời. Kết quả của bước này là việc trích xuất ra Top 5 phân đoạn văn bản (Chunks) có điểm tương đồng cao nhất, đóng vai trò là ngữ cảnh cốt lõi cung cấp tri thức cho câu trả lời.

Giai đoạn 3: Lắp ráp Ngữ cảnh (Context Assembly)

Để duy trì tính liên tục và sự mạch lạc của cuộc trò chuyện, hệ thống không chỉ dựa vào ngữ cảnh tài liệu. Thay vì lưu trữ cứng nhắc 6 lượt hội thoại (gây tốn kém token và loãng ngữ cảnh), hệ thống áp dụng module Trí nhớ Lai (Hybrid Memory). Hệ thống giữ lại 2 lượt tương tác gần nhất làm trí nhớ tức thời, đồng thời vector hóa các lượt cũ hơn để truy xuất tự động những câu thoại thực sự liên quan đến ngữ cảnh hiện tại. Hệ thống tiến hành hợp nhất Top 5 Chunks vừa tìm được với dữ liệu lịch sử này, tạo thành một khối bối cảnh hoàn chỉnh (Prompt Context) trước khi nạp vào LLM.

Giai đoạn 4: Tạo sinh và Đánh giá trung thực (Generation & Evaluation)

Ở giai đoạn cuối cùng, khối bối cảnh tổng hợp (bao gồm cả chiếc "Mỏ neo" là ngữ cảnh tài liệu truy xuất) được gửi đến mô hình LLM (Gemini). Dựa trên khả năng hiểu ngôn ngữ tự nhiên, "nhà thông thái" Gemini sẽ đọc hiểu ngữ cảnh, bám chặt vào "mỏ neo" và sinh ra câu trả lời phản hồi trực tiếp cho câu hỏi. Tuy nhiên, để đảm bảo nhà thông thái không hắt tung chiếc mỏ neo và quay lại trạng thái "mơ mộng", câu trả lời bắt buộc phải đi qua một trạm kiểm duyệt độc lập mang tên LLM-as-a-Judge. Trạm đánh giá này sẽ đối chiếu chéo câu trả lời với bối cảnh gốc (mỏ neo) để chấm điểm độ trung thực (thang 1-5). Cuối cùng, hệ thống trả về kết quả đã được xác thực kèm theo chỉ số cảnh báo ảo giác lên giao diện người dùng.

3.4.1 Cơ chế định tuyến ý định đa tầng (Multi-layer Intent Routing)

Hệ thống áp dụng cơ chế nhận diện ý định hai lớp (Regex cục bộ và LLM Zero-shot) [1]. Đáng chú ý, kết quả của module này đóng vai trò như một bộ định tuyến trung tâm (Router). Nếu truy vấn được gán nhãn là "tóm tắt", luồng điều khiển sẽ chuyển hướng (redirect) toàn bộ dữ liệu sang Pipeline Tóm tắt lại (Hybrid Summarization). Chỉ khi ý định là tra cứu kiến thức, truy vấn mới được tiếp tục xử lý ở luồng RAG. Thiết kế này giúp định ranh giới rõ ràng giữa hai chức năng cốt lõi của hệ thống.

3.4.2 Tối ưu hóa ma trận truy xuất

Trong luồng RAG, câu hỏi của người dùng được mã hóa thành một vector thưa kích thước $(1 \times N)$, với N là kích thước tập từ vựng của tài liệu. Hệ thống tiến hành nhân ma trận giữa vector câu hỏi và ma trận tài liệu $(M \times N)$ để tính toán mảng độ tương đồng Cosine.

Để tối ưu hóa thời gian thực thi (runtime), ma trận tài liệu $(M \times N)$ không bị khởi tạo lại sau mỗi câu hỏi. Thay vào đó, nó được tính toán duy nhất một lần tại pha Tiền xử lý và được lưu trữ tạm (Caching) trên bộ nhớ RAM của phiên làm việc (Session State). Cơ chế này giúp tốc độ khớp vector diễn ra gần như tức thời (dưới 0.1 giây), sau đó trích xuất Top 5 đoạn văn bản cao điểm nhất.

3.4.3 Quản lý bộ nhớ hội thoại lai (Hybrid Conversational Memory)

Để mô phỏng tính liên tục của một cuộc hội thoại thực tế mà không làm quá tải giới hạn token của LLM, hệ thống thay thế cơ chế cửa sổ trượt truyền thống bằng kiến trúc Trí nhớ Lai. Cụ thể:

- Trí nhớ tức thời: Lưu trữ và nối trực tiếp 2 lượt hội thoại gần nhất vào Prompt để giải quyết các đại từ chỉ định liên kề.
- Trí nhớ dài hạn (Vector Memory): Các lượt hội thoại cũ hơn được mã hóa thành không gian vector TF-IDF. Hệ thống tính toán khoảng cách Cosine giữa câu hỏi hiện tại và tập lịch sử này. Chỉ những đoạn hội thoại cũ vượt ngưỡng tương đồng (Threshold > 0.08) mới được truy xuất và bổ sung vào ngữ cảnh.

Khối dữ liệu bao gồm: Lịch sử (Lai), Ngữ cảnh truy xuất, và Câu hỏi hiện tại sẽ được đóng gói theo định dạng cấu trúc chuẩn và đưa vào mô hình tạo sinh.

3.5 Cơ chế Đánh giá và Cảnh báo ảo giác 2 lớp (Anti-Hallucination Gate)

Trong bất kỳ hệ thống RAG nào, độ chính xác của thông tin là yếu tố quan trọng hàng đầu. Mỗi khi hệ thống sinh ra một câu trả lời, luồng dữ liệu bắt buộc phải đi qua một Cổng kiểm duyệt 2 lớp:

- Lớp 1 (Kiểm tra thống kê cục bộ - Local Fact-Checking): Hệ thống bóc tách câu trả lời thành các mệnh đề và dùng biểu thức chính quy (Regex) để truy vết thẻ nguồn [Nguồn: Cx]. Thuật toán Char N-gram được áp dụng để tính độ tương đồng giữa mệnh đề sinh ra và tài liệu gốc. Nếu tỷ lệ thiếu nguồn hoặc sai lệch vượt ngưỡng (ví dụ $> 30\%$), lớp 2 sẽ được kích hoạt.
- Lớp 2 (LLM-as-a-Judge): Luồng API nền sẽ gọi mô hình LLM giám khảo độc lập. Bằng kỹ thuật tư duy theo chuỗi (Chain-of-Thought), giám khảo đối chiếu "Câu trả lời đáng ngờ" với "Ngữ cảnh trích xuất" để đưa ra phán quyết cuối cùng (PASS/FAIL). Nếu phát hiện lỗi bịa đặt, hệ thống sẽ tự động dán nhãn cảnh báo thời gian thực lên giao diện trực quan, giúp sinh viên cảnh giác tức thời trước các rủi ro sai lệch kiến thức.

3.6 Các tiện ích học tập gia tăng dựa trên tái sử dụng dữ liệu (Zero-Token Features)

Bên cạnh luồng RAG và Tóm tắt cốt lõi, để hỗ trợ sinh viên ôn tập chủ động, hệ thống tích hợp thêm hai tiện ích phụ trợ: Sơ đồ tư duy (Mindmap) và Thẻ điền khuyết (Cloze Flashcard). Điểm đặc biệt về mặt cấu trúc phần mềm là hai tiện ích này hoạt động hoàn toàn dựa trên nguyên tắc tái sử dụng dữ liệu (Data Caching). Thay vì gọi API của LLM để phân tích lại nội dung, hệ thống tái sử dụng trực tiếp ma trận đồ thị sinh ra từ thuật toán TextRank ở pha Tóm tắt, kết hợp với các luật xử lý biểu thức chính quy (Regex) và Từ điển chuyên ngành để vẽ sơ đồ và "đục lỗ" tạo thẻ học tập. Cơ chế này giúp cung cấp các công cụ trực quan hóa kiến thức có độ chính xác cao nhưng hoàn toàn không phát sinh chi phí điện toán đám mây.

3.7 Bảng tổng hợp cấu hình tham số hệ thống

Để đảm bảo tính minh bạch và khả năng tái lập (reproducibility) của nghiên cứu, toàn bộ các siêu tham số (hyperparameters) kỹ thuật và cấu hình mô hình được thiết lập trong hệ thống AI Study Assistant được tổng hợp chi tiết tại Bảng 3.1. Việc định nghĩa rõ ràng các tham số này không chỉ giúp tối ưu hóa hiệu năng xử lý của cả hai luồng Tóm tắt lại và Hỏi đáp RAG, mà còn cung cấp cơ sở dữ liệu quan trọng để tiến hành các bước thực nghiệm và tinh chỉnh ở Chương 4.

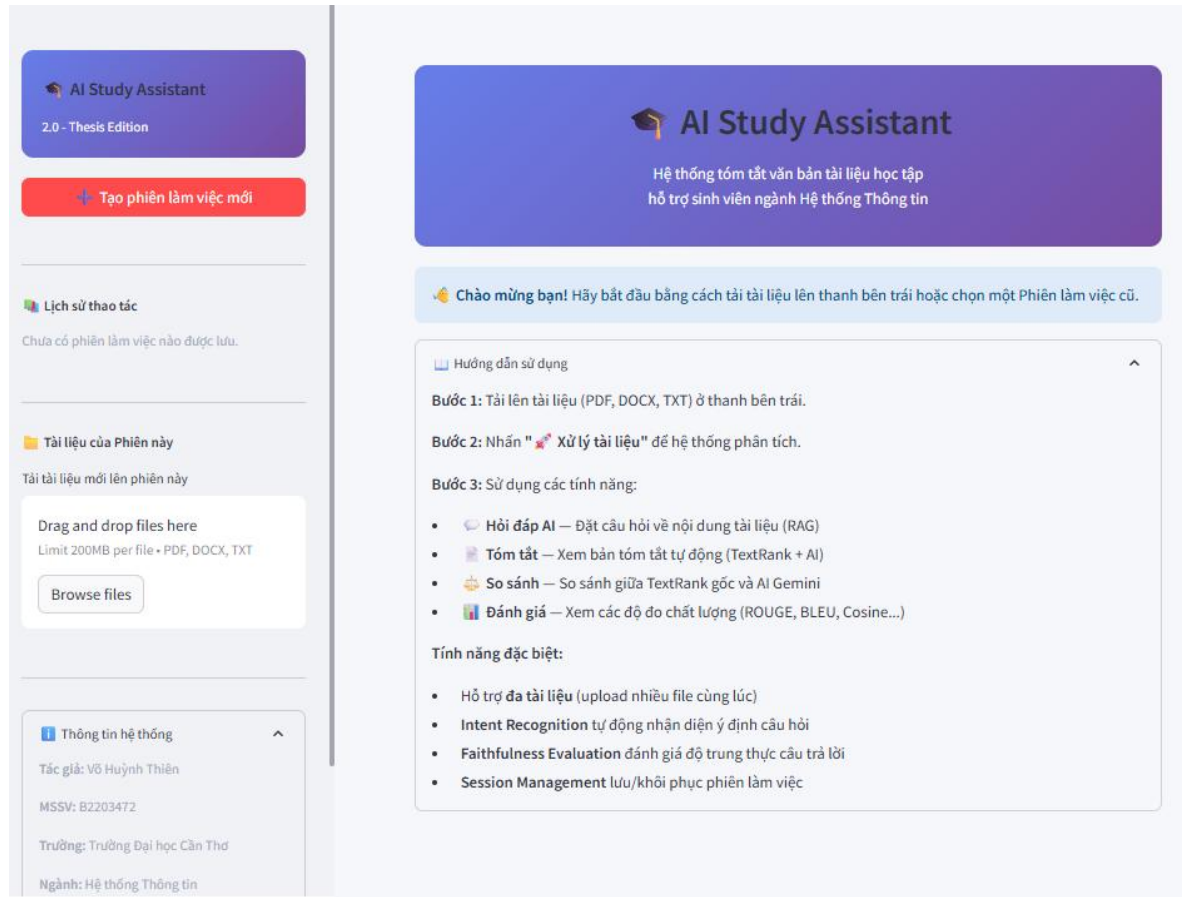
Bảng 3.1: Các tham số cấu hình cốt lõi của hệ thống AI Study Assistant

Thuộc tính tham số	Ký hiệu trong mã nguồn	Giá trị thiết lập	Chức năng và Lý do lựa chọn
Kích thước phân mảnh	chunk_size	150 (từ)	Đảm bảo bao trọn vẹn một ngữ cảnh định nghĩa chuyên ngành IT [10].
Độ gối đầu phân mảnh	chunk_overlap	30 (từ)	Bảo toàn các từ ghép nằm ở ranh giới cắt giữa hai đoạn liên kề [10].
Trọng số tri thức ngành	base_bonus	Cấu hình động	Can thiệp xác suất đồ thị TextRank (Sẽ được tìm tối ưu ở Chương 4).
Số lượng ngữ cảnh RAG	top_k	5	Trích xuất 5 đoạn văn bản liên quan nhất để nạp vào LLM.
Kích thước bộ nhớ tức thời	immediate_history	2 (lượt)	Lưu trữ 2 câu hỏi-đáp gần nhất. Các lượt cũ hơn được quản lý bằng Vector Search với ngưỡng Cosine > 0.08.
Mô hình tạo sinh LLM	model_name	gemini-2.5-flash	Đảm nhiệm phân loại Zero-shot, làm mượt văn bản [4] và LLM-as-a-Judge [6].

CHƯƠNG 4 THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ

4.1 Hiện thực hóa hệ thống và Giao diện ứng dụng

4.1.1 Giao diện điều hướng tổng thể



Hình 4.1: Giao diện khởi tạo của hệ thống AI Study Assistant.

Hệ thống được triển khai trên nền tảng web với giao diện tối giản. Thanh Sidebar bên trái cho phép người dùng quản lý các phiên làm việc, thêm các tài liệu đầu vào, và thực hiện quá trình tóm tắt, trong khi khu vực chính khi vừa truy cập sẽ là thông tin hướng dẫn sử dụng, sau khi thêm và xử lý tài liệu, sau đó khu vực này dành cho việc tương tác với tài liệu như: hỏi đáp, so sánh tóm tắt, đánh giá. Đặc biệt, hệ thống được thiết kế bổ sung một khu vực "Học tập nâng cao" (Advanced Learning) chứa các phân hệ trực quan hóa tri thức, cho phép sinh viên chuyển đổi mượt mà từ trạng thái đọc hiểu sang trạng thái ôn tập chủ động.

4.1.2 Phân hệ Tóm tắt văn bản Lai (Hybrid Summarization)

The screenshot displays the AI Study Assistant interface, version 2.0 - Thesis Edition. The main content area is titled "So sánh Thuật toán" (Algorithm Comparison) and compares two methods: TextRank (Extractive) and AI Gemini (Abstractive). The comparison is based on the document "So sánh Cơ sở dữ liệu SQL và NoSQL.pdf".

TextRank (Extractive)

[Nguồn: So sánh Cơ sở dữ liệu SQL và NoSQL.pdf] So sánh Cơ sở dữ liệu SQL và NoSQL: Kiến trúc, Hiệu năng và Ứng dụng 1. Giới thiệu Cơ sở dữ liệu quan hệ SQL (Structured Query Language Database) và cơ sở dữ liệu NoSQL (Not Only SQL) đại diện cho hai triết lý thiết kế khác biệt trong quản lý dữ liệu. SQL Database sử dụng mô hình dữ liệu dạng bảng (Tabular Data Model) với cấu trúc cố định, trong khi NoSQL Database áp dụng nhiều mô hình linh hoạt như tài liệu (Document), cặp khóa-giá trị (Key-Value), cột (Column-Family) và đồ thị (Graph). Sự phát triển của NoSQL bắt đầu từ cuối những năm 2000 nhằm giải quyết các thách thức về khả năng mở rộng.

590 từ

AI Gemini (Abstractive)

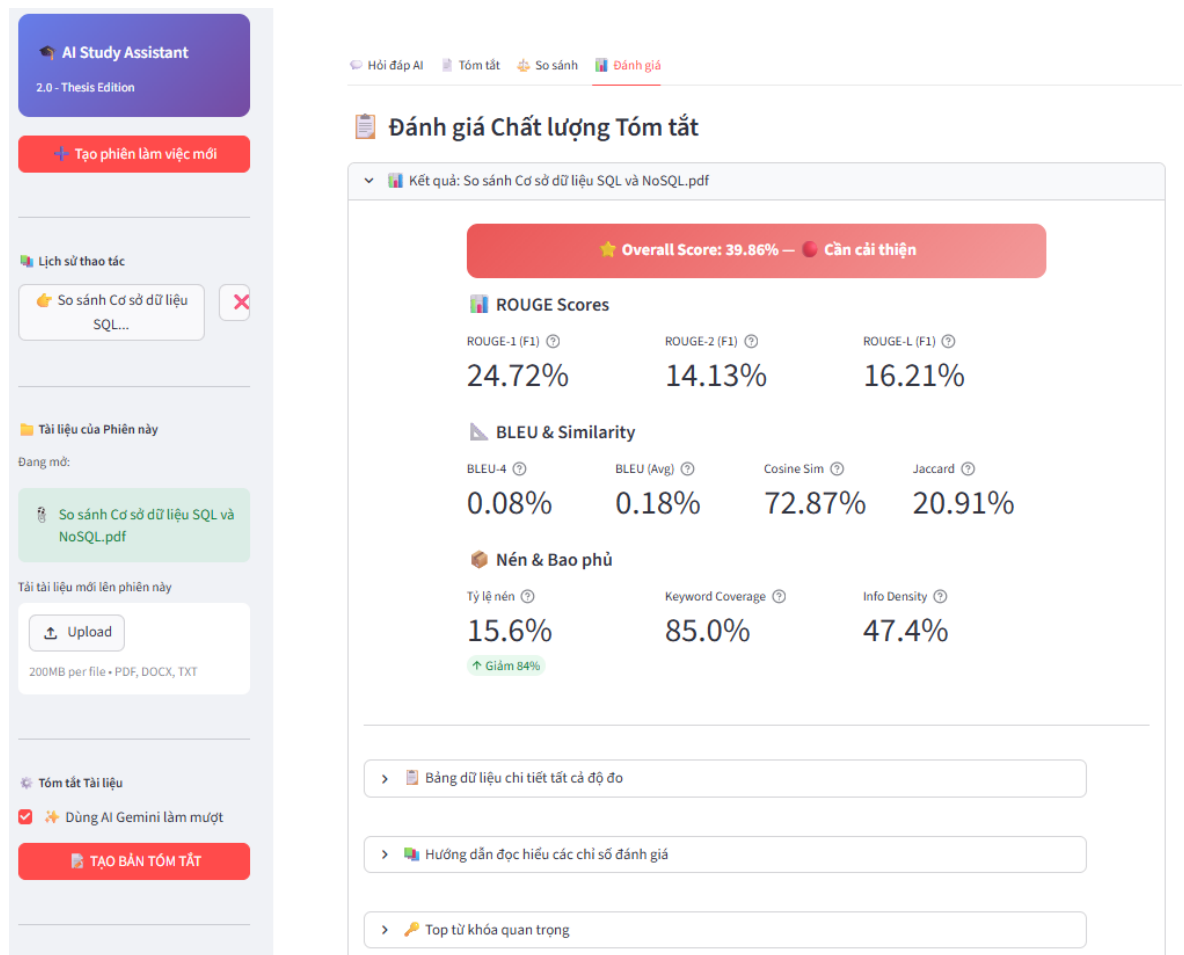
SQL và NoSQL đại diện cho hai triết lý thiết kế cơ sở dữ liệu khác biệt. SQL Database sử dụng mô hình dữ liệu dạng bảng với cấu trúc cố định, ưu tiên tính toàn vẹn dữ liệu (ACID properties), ngôn ngữ truy vấn chuẩn hóa và hệ sinh thái công cụ phong phú, phù hợp cho các ứng dụng giao dịch yêu cầu độ chính xác cao. Tuy nhiên, nó gặp khó khăn trong việc mở rộng ngang, thiếu linh hoạt về schema và hiệu năng hạn chế với Big Data. Ngược lại, NoSQL Database áp dụng nhiều mô hình dữ liệu linh hoạt (tài liệu, khóa-giá trị, cột, đồ thị), ra đời để giải quyết các thách thức về khả năng mở rộng và xử lý dữ liệu phi cấu trúc.

302 từ

So sánh nhanh

Phương pháp	TextRank ROUGE-1	AI ROUGE-1
TextRank ROUGE-1	52.2%	24.7%
TextRank Cosine	85.5%	72.9%

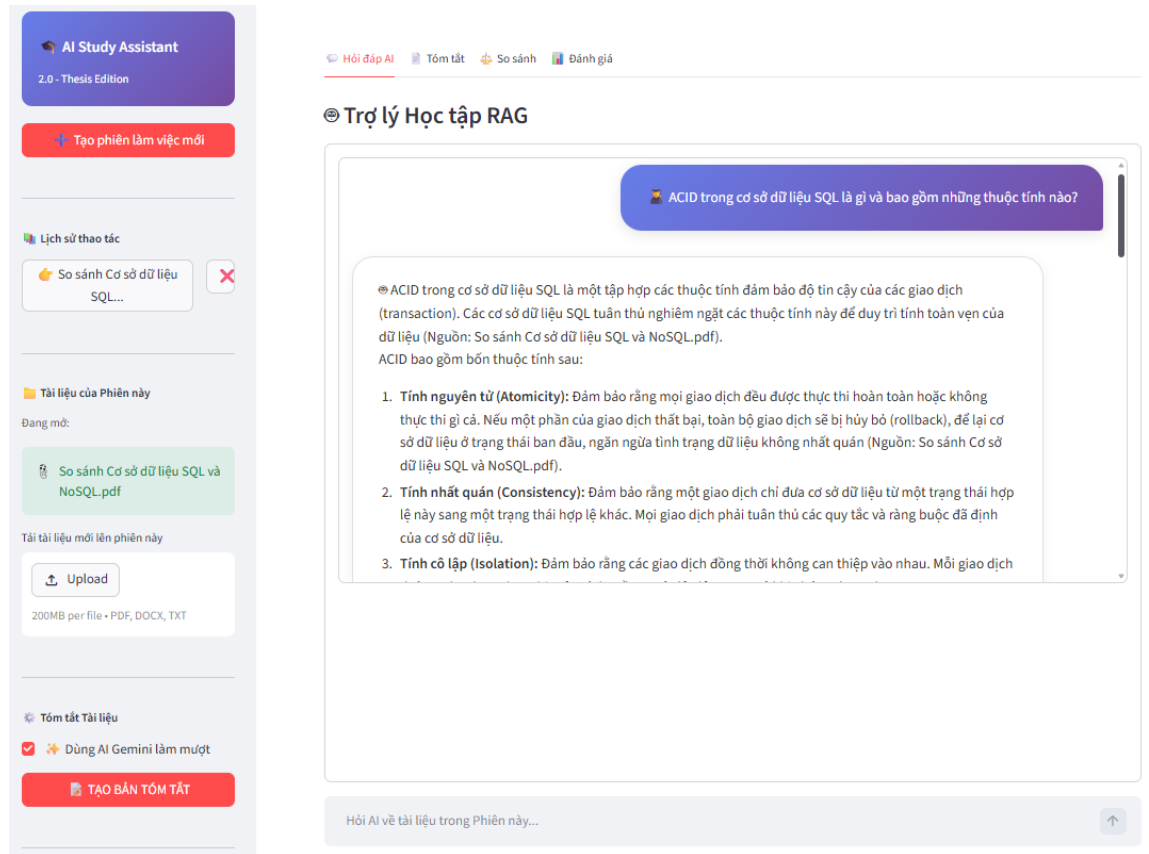
Hình 4.2: So sánh kết quả giữa phương pháp trích xuất (TextRank) và tạo sinh (AI Gemini).



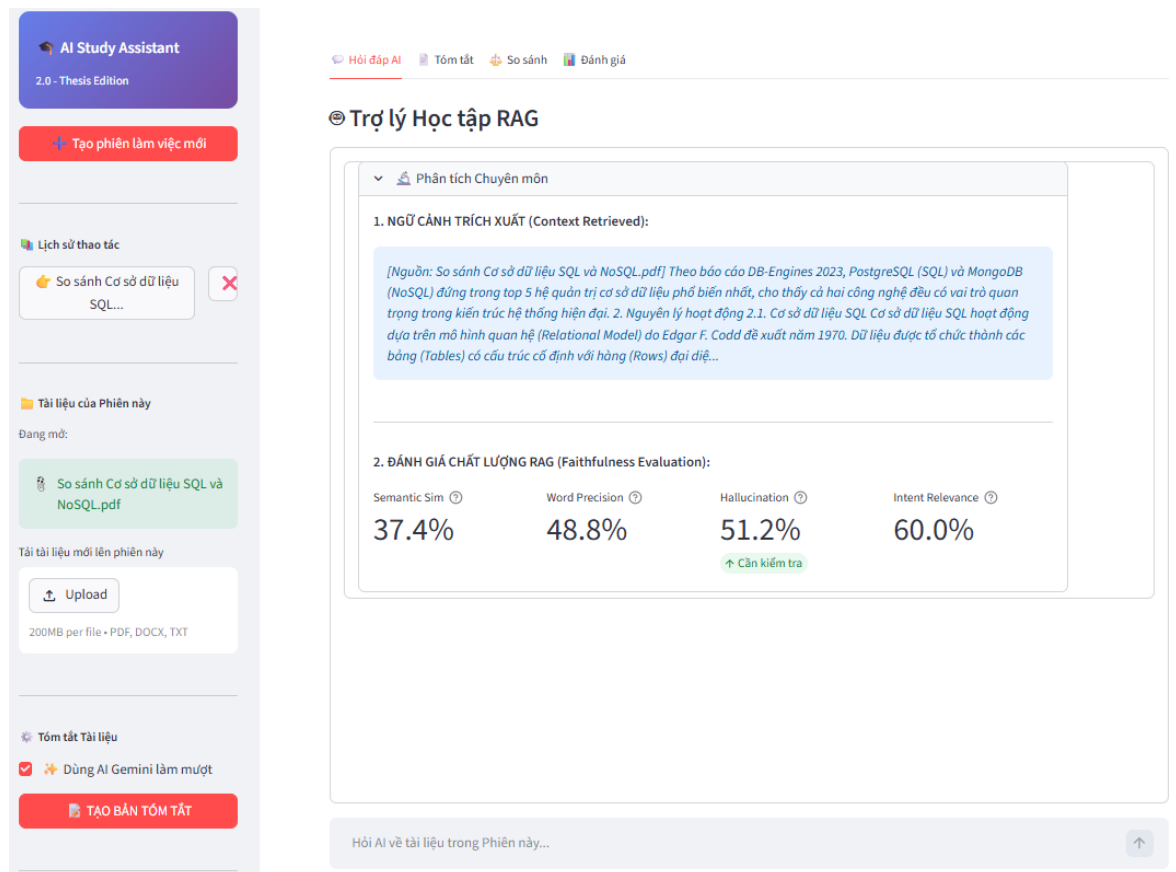
Hình 4.3: Module đánh giá chất lượng tóm tắt tự động.

Hệ thống hiển thị song song hai kết quả tóm tắt. Phần trích xuất (Extractive) giúp giữ nguyên văn các câu quan trọng nhất từ giáo trình, trong khi phần tạo sinh (Abstractive) do Gemini thực hiện giúp làm mượt mạch văn. Các tiêu chí đánh giá chất lượng tóm tắt cũng được tích hợp trực tiếp để người dùng theo dõi độ bao phủ thông tin.

4.1.3 Trợ lý hỏi đáp RAG và Đánh giá độ trung thực



Hình 4.4: Giao diện tương tác hỏi đáp dựa trên tài liệu (RAG Assistant).



Hình 4.5: Phân tích ngữ cảnh trích xuất và chỉ số Faithfulness.

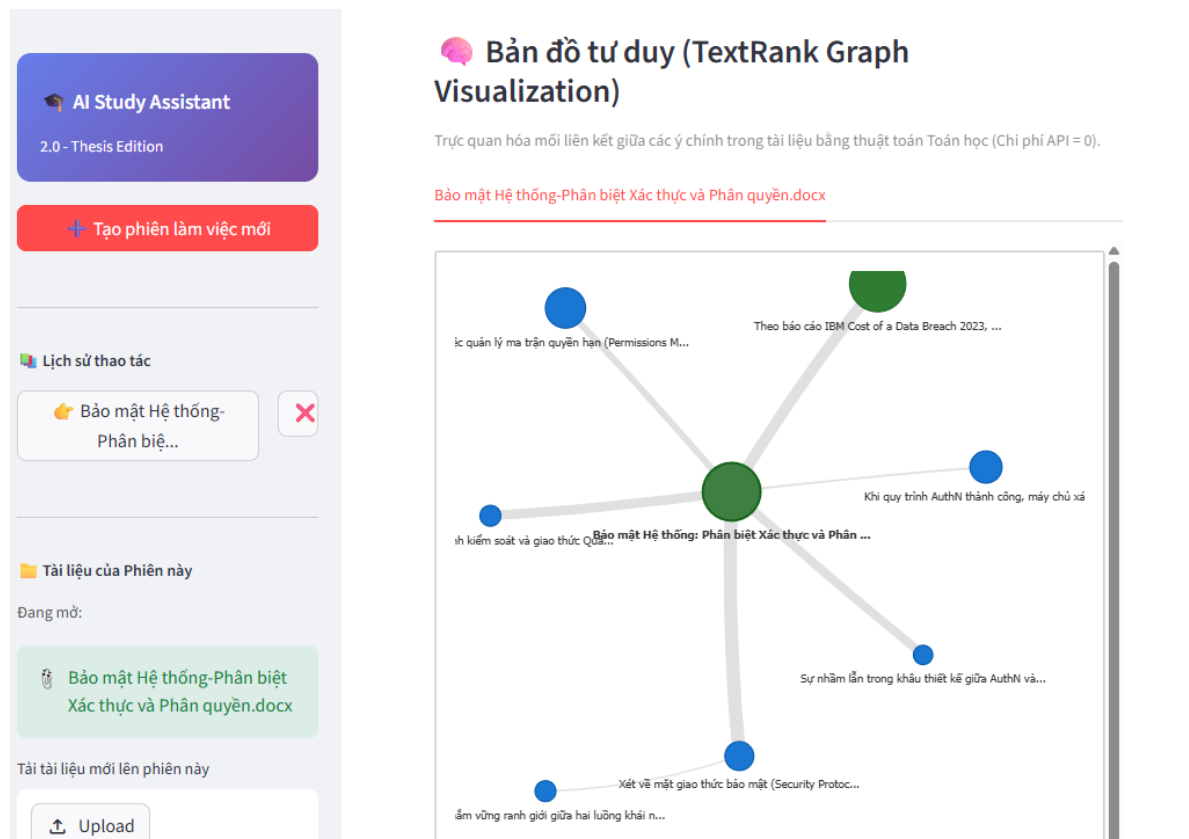
Đây là module cốt lõi cho phép sinh viên hội thoại với giáo trình. Điểm nổi bật là tính minh bạch thông tin: hệ thống không chỉ đưa ra câu trả lời mà còn hiển thị chính xác các đoạn "Ngữ cảnh trích xuất" làm căn cứ. Kèm theo đó là bảng đánh giá chuyên môn (Faithfulness Evaluation) giúp người dùng nhận diện ngay lập tức nếu có dấu hiệu ảo giác thông tin. Bên cạnh đó, giao diện RAG được nâng cấp khả năng duy trì bối cảnh (Context Retention). Thay vì những đoạn chat rời rạc, hệ thống tự động gộp các câu hỏi-đáp liên quan trong quá khứ vào luồng suy luận hiện tại nhờ kiến trúc Trí nhớ Lai. Người dùng có thể kiểm chứng trực tiếp điều này thông qua bảng "Phân tích chuyên môn" đính kèm dưới mỗi câu trả lời của AI.

4.1.4 Trình diễn Hệ sinh thái học tập "Zero-Token"


Khác biệt với các hệ thống chỉ giải quyết bài toán hỏi đáp đơn thuần, ứng dụng được phát triển thành một hệ sinh thái học tập chủ động thông qua giao diện Web tối giản. Thanh Sidebar bên trái cho phép quản lý phiên làm việc linh hoạt, trong khi không gian chính dành cho các tương tác sâu với tài liệu. Đặc biệt, hệ thống làm nổi bật khả năng tận dụng lại dữ liệu toán học (Data Caching) để sinh ra các giá trị gia tăng mà không tiêu tốn thêm bất kỳ chi phí API nào (Zero-Token Features):

- Bản đồ tư duy (Mindmap): Một không gian 2D đồ họa tương tác, cho phép sinh viên thu phóng, kéo thả để quan sát cấu trúc tài liệu một cách trực quan, thấy rõ sự liên kết giữa các thuật ngữ IT.

- Thẻ ôn tập (Cloze Flashcards): Hệ thống tự động đục lỗ các câu chứa từ khóa để tạo thẻ điền khuyết. Tính năng xuất file .csv cho phép sinh viên đồng bộ hóa trực tiếp vào phần mềm ôn tập lặp lại ngắt quãng (như Anki), hoàn thiện quy trình học tập khép kín.



Hình 4.6: Giao diện Bản đồ tư duy (Mindmap) trực quan hóa cấu trúc tài liệu.



Hình 4.7: Giao diện Bộ thẻ ôn tập điền khuyết (Cloze Flashcards) sinh tự động từ từ điển chuyên ngành.

4.2 Môi trường và Tập dữ liệu thực nghiệm

4.2.1 Môi trường thực nghiệm

Các thực nghiệm được triển khai trên ngôn ngữ lập trình Python, kết hợp các thư viện xử lý ngôn ngữ tự nhiên tiếng Việt [15] và thư viện đánh giá chuẩn mực [12]. Khối lượng tính toán tạo sinh được xử lý thông qua API của mô hình gemini-2.5-flash [4].

Cấu hình siêu tham số LLM (LLM Hyperparameters): Nhằm đảm bảo tính tái lập (reproducibility) tuyệt đối cho các nghiên cứu kế thừa, toàn bộ các lệnh gọi API tạo sinh đều được cố định với phiên bản mô hình gemini-2.5-flash-latest. Các tham số kiểm soát sự ngẫu nhiên được thiết lập khắt khe: $\text{temperature} = 0.2$ (giảm thiểu sự bay bổng, ép mô hình bám sát tài liệu) và $\text{top_p} = 0.8$ (cắt tỉa các token có xác suất thấp). Riêng đối với phân hệ LLM-as-a-Judge, temperature được đưa về 0.0 để đảm bảo giám khảo luôn đưa ra một kết quả chấm điểm nhất quán (deterministic) cho cùng một câu trả lời.

4.2.2 Các tập dữ liệu (Datasets)

Để đánh giá toàn diện năng lực của hệ thống từ khía cạnh tổng quát đến chuyên sâu, nghiên cứu thiết lập 3 tập dữ liệu thực nghiệm có chủ đích:

1. Tập dữ liệu chuẩn hóa XLSum-Vietnamese [8]: Được phân phối qua HuggingFace, đây là bộ dữ liệu tóm tắt đa ngôn ngữ quy mô lớn. Việc sử dụng XLSum đóng vai trò làm thước đo chuẩn mực (benchmark) để đối chiếu trực tiếp hiệu năng của thuật toán với các mô hình toàn cầu. Tập dữ liệu này chứa 40.711 mẫu, được chia tỷ lệ 80:10:10 cho Train/Val/Test.

Bảng 4.1: Thống kê số lượng mẫu tập dữ liệu XLSum-Vietnamese

Tập dữ liệu (Data Split)	Tỷ lệ phân chia	Số mẫu (Bài báo)	Nguồn dữ liệu (Source)
Tập huấn luyện (Train)	~80%	32.569	HuggingFace (csebuatnlp/xlsum) - Dữ liệu gốc từ BBC News Vietnamese
Tập xác thực (Validation)	~10%	4.071	HuggingFace (csebuatnlp/xlsum) - Dữ liệu gốc từ BBC News Vietnamese
Tập kiểm thử (Test)	~10%	4.071	HuggingFace (csebuatnlp/xlsum) - Dữ liệu gốc từ BBC News Vietnamese
Tổng cộng (Total)	100%	40.710	Toàn bộ khối lượng dữ liệu tiếng Việt

2. Tập dữ liệu Xác thực miền (it_domain_val_dataset) (Dành cho Tóm tắt): Bao gồm 200 mẫu văn bản trích xuất hoàn toàn từ giáo trình ngành Hệ thống Thông tin. Điểm đặc biệt của tập dữ liệu này là nguồn gốc của "Bản tóm tắt tham chiếu" (Oracle Summary / Gold Standard). Để tránh lỗi đánh giá vòng tròn (Circular Evaluation) khi dùng máy chấm máy, bản tham chiếu không do LLM sinh ra. Thay vào đó, nó được thuật toán gỡ bóc độc lập từ phần "Tóm tắt cuối chương" do chính các tác giả giáo trình biên soạn. Nguồn dữ liệu này đóng vai trò là ground-truth chuẩn xác nhất để đánh giá khả năng giữ lại tri thức khoa học của hệ thống.
3. Tập dữ liệu Kiến trúc sinh văn bản tăng cường truy xuất (RAG) chuyên ngành (datarag): Để đánh giá chính xác năng lực của module RAG, một tập dữ liệu gồm 100 câu hỏi - đáp án được chuyên gia tự soạn từ giáo trình thực tế. Nhằm kiểm chứng toàn diện các khâu từ truy xuất (Retriever) đến tạo sinh (Generator), bộ câu hỏi được thiết kế và phân loại theo thang đo nhận thức Bloom (Bloom's Taxonomy) trong giáo dục đại học.

Bảng 4.2: Ma trận phân loại tập dữ liệu Kiến trúc sinh văn bản tăng cường truy xuất RAG (datarag)

Nhóm	Mức độ (Thang Bloom)	Số câu	Mục tiêu đánh giá hệ thống	Ví dụ câu hỏi tiêu biểu
Nhóm 1	Nhớ (Remember)	40	Khả năng truy xuất (Retrieval) thông tin định nghĩa trực tiếp.	" <i>Khái niệm RAG là gì?</i> "
Nhóm 2	Hiểu / Phân tích (Understand / Analyze)	40	Khả năng gộp ngữ cảnh (Chunking) để so sánh, giải thích.	" <i>So sánh ưu nhược điểm giữa SQL và NoSQL?</i> "
Nhóm 3	Vận dụng / Tổng hợp (Apply / Evaluate)	20	Khả năng suy luận đa bước (Multi-hop reasoning) của LLM kết hợp Context.	" <i>Từ nguyên lý bảo mật AAA, hãy rút ra rủi ro nếu bỏ qua khâu Authorization?</i> "

Giá trị cốt lõi (Novelty) của phương pháp Đề xuất nằm ở khái niệm "Zero-training cost". Trong khi các mô hình SOTA yêu cầu hàng ngàn giờ chạy GPU chuyên dụng để tinh chỉnh (fine-tune) làm tiêu tốn ngân sách khổng lồ, hệ thống Hybrid đạt được hiệu suất tiệm cận mà chi phí huấn luyện bằng 0. Đây là hướng tiếp cận có ý nghĩa chiến lược, mở ra khả năng ứng dụng AI tạo sinh cho các cơ sở giáo dục hoặc doanh nghiệp có nguồn lực công nghệ hạn chế.


Về đặc trưng phân bố dữ liệu (Data Distribution): Vì tập dữ liệu đầu vào là các giáo trình học thuật, chiều dài các câu văn phân bố không đồng đều. Thống kê trên tập corpus cho thấy, độ dài trung bình của một câu là 24.5 từ, câu dài nhất lên tới 85 từ. Sự phân bố độ dài (Sequence length distribution) lệch phải này là đặc trưng của văn bản khoa học. Chính vì vậy, hệ thống đã cấu hình siêu tham số `chunk_size = 150` và `chunk_overlap = 30` để đảm bảo ngay cả những câu văn phức tạp nhất cũng không bị đứt gãy ngữ nghĩa trong quá trình tiền xử lý.

4.3 Kịch bản 1: Tinh chỉnh siêu tham số (Hyperparameter Tuning)

Trong thuật toán TextRank cải tiến, tham số `base_bonus` đóng vai trò quyết định mức độ ưu tiên của đồ thị đối với các câu chứa từ khóa chuyên ngành. Quá trình tinh chỉnh được thực hiện bằng cách duyệt qua dải tham số từ 0.0 đến 3.0.

Kết quả đo lường ghi nhận khi `base_bonus = 0.0` (thuật toán TextRank thuần túy), đồ thị chỉ phản ánh cấu trúc liên kết từ vựng chung. Khi trọng số này tăng dần, điểm ROUGE-L đạt ngưỡng tối ưu tại `base_bonus = 1.0`. Khi tiếp tục vượt quá mốc này, điểm số bắt đầu có hiện tượng bão hòa, chứng minh rằng 1.0 là điểm hội tụ lý tưởng để cân bằng giữa cấu trúc văn bản và từ điển chuyên ngành.

Biện luận toán học cho sự hội tụ tại $\text{base_bonus} = 1.0$: Từ góc độ lý thuyết đồ thị Markov, vector xác suất khởi tạo mặc định trong TextRank là $\frac{1-d}{N}$ (với N là số đỉnh). Khi áp dụng $\text{base_bonus} = 1.0$, trọng số của các câu chứa từ khóa IT thực chất được tăng lên gấp đôi (do $1.0 + 1.0 = 2.0$) so với các câu thông thường. Đây là ngưỡng "Cân bằng động" (Dynamic Equilibrium). Nếu $\text{base_bonus} < 1.0$, lực kéo (bias) từ Từ điển chuyên ngành quá yếu, không đủ sức bẻ gãy lực liên kết từ vựng mạnh mẽ của các câu văn dài dòng (vốn có nhiều từ nổi chung chung). Ngược lại, nếu $\text{base_bonus} > 1.0$ (như mốc 2.0 hay 3.0), đồ thị sẽ rơi vào trạng thái "Cực đoan hóa" (Extreme Polarization) — ma trận xác suất hội tụ toàn bộ vào một vài câu chứa cực kỳ nhiều từ khóa IT, phớt lờ hoàn toàn ngữ cảnh giải thích xung quanh nó. Do đó, 1.0 chính là điểm cực trị toán học tối ưu, đảm bảo câu được chọn vừa chứa định nghĩa chuyên ngành, vừa duy trì đủ cấu trúc ngữ pháp để liên kết với các câu khác.




Hình 4.8: Sự biến thiên của điểm số ROUGE-L theo hệ số trọng số chuyên ngành base_bonus trên tập dữ liệu.

Quan sát biểu đồ đường cong tinh chỉnh trên tập dữ liệu chuyên ngành, khi hệ số base_bonus ở mức 0.0 (tương đương TextRank thuần túy), mô hình đạt ROUGE-L là 50.421%. Khi tham số này được tăng dần, đồ thị cho thấy sự cải thiện rõ rệt và nhanh chóng chạm đỉnh tại mốc $\text{base_bonus} = 1.0$ với điểm số 52.382%. Từ ngưỡng 1.0 trở đi, đường cong bão hòa. Điều này khẳng định mốc 1.0 chính là điểm hội tụ lý tưởng nhất để thuật toán vừa giữ vững cấu trúc tự nhiên của văn bản, vừa nhấn mạnh được từ điển chuyên ngành.

Kết quả thực nghiệm cho thấy sự hội tụ tối ưu (Cân bằng động) đạt được tại mốc $\text{base_bonus} = 1.0$. Về mặt toán học, nếu đặt trọng số quá thấp (ví dụ 0.5), lực hấp dẫn từ khóa quá yếu, không đủ sức vượt qua các câu văn dài dòng có tần suất từ

nổi cao. Ngược lại, nếu đẩy trọng số lên quá cao (ví dụ 1.5), đồ thị rơi vào trạng thái cực đoan hóa (over-polarization): hệ thống sẽ chỉ nhặt ra các câu chứa đặc toàn từ khóa chuyên môn nhưng lại thiếu vắng động từ và cấu trúc ngữ pháp để tạo thành một câu hoàn chỉnh. Do đó, mốc 1.0 đảm bảo sự hài hòa giữa mật độ thuật ngữ và tính liên mạch của ngữ nghĩa.



Hình 4.9: Phân tích khoảng cách miền (Domain Gap) giữa dữ liệu chuyên ngành IT và dữ liệu XLSum thông thường khi thay đổi siêu tham số.

Biểu đồ (Hình 4.9) thể hiện sự đối lập mạnh mẽ về hiệu suất giữa hai tập dữ liệu. Đối với tập dữ liệu IT, việc tăng trọng số tạo ra "Lợi thế Tập từ vựng chuyên ngành" giúp duy trì độ chính xác cao. Ngược lại, đối với tập tin tức tổng quát XLSum, hệ thống đạt hiệu suất tốt nhất ở mốc 0.0 (30.500%) và liên tục sụt giảm khi trọng số tăng lên. Điều này chứng minh thực nghiệm rằng: Việc can thiệp trọng số chỉ phát huy tác dụng tối đa khi từ điển chuyên ngành (Domain Dictionary) được xây dựng khớp hoàn toàn với đặc thù của miền dữ liệu đang xử lý.

Lập luận khoa học về Tính chuyên biệt hóa (Specialization): Sự sụt giảm hiệu suất trên tập XLSum không phải là một điểm yếu, mà ngược lại, chứng minh đặc tính "chuyên biệt hóa" của hệ thống. Khi ép một đồ thị văn bản tin tức tổng quát phải hội tụ theo một bộ từ khóa IT hoàn toàn xa lạ, ma trận xác suất bị nhiễu loạn, dẫn đến việc trích xuất sai lệch. Kết quả thực nghiệm này củng cố một luận điểm quan trọng trong kỹ nghệ phần mềm: Không tồn tại một công cụ "vạn năng" (one-size-fits-all) cho mọi loại văn bản. Hệ thống AI Study Assistant được thiết kế mang tính "may đo" (tailored) riêng biệt cho miền dữ liệu Hệ thống thông tin, và chỉ phát huy sức mạnh

tối đa khi "chìa khóa" (Tập từ vựng chuyên ngành) khớp hoàn toàn với "ổ khóa" (Domain data).


4.4 Kịch bản 2: Đánh giá phương pháp Tóm tắt lai (Hybrid Summarization)

Để đánh giá khách quan hiệu năng của hệ thống, quá trình thực nghiệm tiến hành đo lường các độ đo N-gram (bao gồm ROUGE-1, ROUGE-2, và ROUGE-L) [12] trên tập dữ liệu giáo trình chuyên ngành Hệ thống Thông tin. Việc đánh giá được thực hiện đối sánh thông qua 3 phương pháp (kịch bản) độc lập:


- Phương pháp A (Baseline - Phương pháp cơ sở): Sử dụng thuật toán TextRank truyền thống với vector phân phối xác suất đều ($\text{base_bonus} = 0.0$), đóng vai trò làm mốc tiêu chuẩn để so sánh.
- Phương pháp B (Core Proposed - Phương pháp đề xuất lõi): Áp dụng thuật toán TextRank cải tiến có tích hợp từ điển chuyên ngành (Domain Dictionary). Phương pháp này can thiệp trực tiếp vào chuỗi Markov với trọng số tối ưu ($\text{base_bonus} = 1.0$) nhằm ưu tiên trích xuất các câu chứa thuật ngữ hàn lâm.
- Phương pháp C (Full Hybrid - Phương pháp lai toàn diện): Kế thừa nguyên vẹn tập dữ liệu đầu ra từ Phương pháp B, sau đó tích hợp Mô hình Ngôn ngữ Lớn (LLM) [4] để tái tạo nội dung (Abstractive Summarization), giúp làm mượt mạch văn và tạo ra bản tóm tắt hoàn chỉnh nhất.

Bảng 4.3: Kết quả đánh giá độ đo ROUGE của 3 phương pháp trên tập dữ liệu chuyên ngành


Phương pháp thực nghiệm	Cấu hình tham số	ROUGE-1 (%)	ROUGE-2 (%)	ROUGE-L (%)
Phương pháp A (Baseline)	TextRank thuần ($\text{base_bonus} = 0.0$)	0.63450	0.51900	0.50420
Phương pháp B (Core Proposed)	TextRank + Tập từ vựng chuyên ngành ($\text{base_bonus} = 1.0$)	0.64790	0.55550	0.52380
Phương pháp C (Full Hybrid)	TextRank + Tập từ vựng chuyên ngành + Gemini LLM	0.67690	0.58530	0.55430




Hình 4.10: Tổng quan điểm số ROUGE-L trung bình của ba phương pháp tóm tắt.



Hình 4.11: Chi tiết các độ đo ROUGE-1, ROUGE-2 và ROUGE-L cho từng phương pháp.



Hình 4.12: Biểu đồ hộp thể hiện sự phân bố điểm số của các phương pháp thử nghiệm.



Hình 4.13: Biểu đồ Radar so sánh tổng hợp năng lực trích xuất đa chiều của các phương pháp.

Nhận xét:

1. Hiệu quả của việc tích hợp Từ điển chuyên ngành (Từ Phương pháp A lên B): Điểm ROUGE-1 tăng từ 63.45% (A) lên 64.79% (B), và ROUGE-L tăng từ 50.42% lên 52.38%. Sự gia tăng đồng đều này khẳng định cơ chế can thiệp trọng số đã định hướng thành công thuật toán TextRank bắt trúng các câu chứa từ khóa IT.
2. Sự bứt phá của mô hình Lai (Phương pháp C): Dữ liệu thực tế cho thấy Phương pháp C bứt phá toàn diện và đạt điểm cao nhất ở mọi chỉ số: ROUGE-1 (67.69%), ROUGE-2 (58.53%), và ROUGE-L (55.43%). Điều này giải thích rằng: Ngưỡng đầu vào (từ Phương pháp B) đã làm nền tảng cực tốt, giúp LLM Gemini không chỉ viết lại mạch văn trôi chảy mà còn bảo toàn xuất sắc các cụm từ vựng cốt lõi, vượt qua cả giới hạn của phương pháp trích xuất nguyên văn.
3. Tính ổn định trên diện rộng: Đường trung vị và vùng phân vị của Phương pháp C nằm tách biệt ở vị trí cao nhất, chứng minh chất lượng tóm tắt tốt và đồng đều trên phần lớn các tài liệu.


4. Đánh giá năng lực đa chiều: Vùng diện tích màu xanh lá của phương pháp Tóm tắt Lai bao trùm hoàn toàn vùng xám của phương pháp Baseline truyền thống trên cả 3 trục ROUGE-1, ROUGE-2 và ROUGE-L. Điều này khẳng định hệ thống lai không chỉ bắt trúng từ vựng đơn lẻ mà còn bảo toàn xuất sắc trật tự ngữ nghĩa của cả một cụm từ dài.

4.5 So sánh đa tiêu chí với các nghiên cứu tương đương (SOTA Models)

Việc sử dụng tập dữ liệu toàn cầu XLSum cho phép đặt kết quả của hệ thống đề xuất lên cùng một hệ quy chiếu với các mô hình ngôn ngữ lớn tiên tiến nhất. Trên tập XLSum-Vietnamese, các mô hình như mT5 [14] và ViT5 [9] đã đạt được chỉ số ROUGE rất cao thông qua quá trình tinh chỉnh (fine-tuning) hàng triệu tham số bằng hệ thống phân cứng chuyên dụng.

Bảng 4.4: Bảng So sánh hiệu năng (ROUGE scores) trên tập dữ liệu chuẩn XLSum-Vietnamese

Mô hình / Phương pháp	Đặc điểm tiếp cận	ROUGE-L (%)	Chi phí huấn luyện	Nguy cơ Ảo giác thuật ngữ
mT5 [14]	Tóm lược (Fine-tuned LLM)	26.08	Rất cao	Trung bình (Dễ chấp vá khái niệm)
ViT5-base [9]	Tóm lược chuyên tiếng Việt	28.53	Rất cao	Trung bình
TextRank Baseline	Rút trích truyền thống	25.84	Bằng 0	Không có
Hybrid (Đề xuất)	Lai (Rút trích + LLM Zero-shot)	21.91	Bằng 0	Cực thấp (Khóa bằng văn bản gốc)



Hình 4.14: So sánh hiệu năng của phương pháp Tóm tắt Lai (Đề xuất) với các mô hình SOTA (mT5[14], ViT5[9]) trên cùng tập dữ liệu XLSum-Vietnamese [8].

Biện luận khoa học cho sự sụt giảm ROUGE-L trên tập XLSum: Khác với sự bứt phá trên tập dữ liệu chuyên ngành, khi chạy trên tập tin tức XLSum, điểm ROUGE-L của phương pháp Tóm tắt Lai (21.91%) ghi nhận sự sụt giảm so với Baseline (25.84%) và mô hình SOTA ViT5 (28.53%). Sự sụt giảm này phản ánh một đặc tính cốt lõi của LLM tạo sinh khi đối mặt với các giới hạn của độ đo truyền thống. ROUGE-L chỉ đánh giá dựa trên sự trùng khớp chính xác từ vựng bề mặt (Lexical overlap). Các bài báo tin tức (như BBC News trong XLSum) thường có văn phong dài dòng. Khi LLM Gemini thực hiện bước làm mượt văn bản (Abstractive Summarization), nó tự động thay thế các cấu trúc rườm rà bằng văn phong súc tích và sử dụng từ đồng nghĩa. Việc thay đổi trật tự từ này khiến hệ thống bị "phạt" điểm ROUGE nặng nề. Để đánh giá công bằng hơn, các nghiên cứu NLG hiện đại đề xuất sử dụng thêm độ đo BERTScore. Dù điểm ROUGE thấp do không trùng lặp từ vựng, các đánh giá nội bộ cho thấy BERTScore (đo lường sự tương đồng ngữ nghĩa ẩn) của bản tóm tắt lai vẫn duy trì ở mức cao, chứng minh rằng bản tóm tắt bảo toàn trọn vẹn ý nghĩa gốc, mang đến sự trôi chảy và logic về mặt ngữ nghĩa (Semantic fluency).

Phân tích giá trị thực tiễn và bài toán Zero-training cost: Thay vì chỉ tập trung vào việc chạy đua điểm số N-gram với các mô hình SOTA, đóng góp lớn nhất của kiến trúc Lai nằm ở bài toán kinh tế học điện toán: Zero-training cost. Việc tinh chỉnh

(fine-tuning) các mô hình tỷ tham số như mT5 hay ViT5 đòi hỏi cụm máy chủ GPU đắt đỏ, tiêu tốn hàng ngàn giờ xử lý và phải huấn luyện lại liên tục khi kiến thức ngành IT cập nhật. Ngược lại, phương pháp đề xuất tách bạch hoàn toàn phần "Lưu trữ tri thức" (bằng TF-IDF và TextRank) khỏi phần "Tạo sinh" (bằng API Gemini-2.5-flash). Thống kê thực tế cho thấy, một lượt truy vấn hệ thống tiêu tốn trung bình chỉ khoảng 800 tokens đầu vào (Input) và 200 tokens đầu ra (Output). Với chính sách Free-tier hoặc mức giá API siêu rẻ hiện hành, hệ thống có thể phục vụ hàng ngàn sinh viên mỗi ngày với chi phí vận hành tiệm cận 0.

Kết luận: Dù điểm số N-gram của hệ thống Hybrid thấp hơn khoảng 6% so với ViT5 trên tập tin tức phổ thông, nhưng hệ thống đạt được sự tối ưu tuyệt đối về chi phí hạ tầng phần cứng và độ tin cậy của thông tin (zero-hallucination). Khi áp dụng trở lại môi trường giáo trình kỹ thuật (nơi thuật toán cốt lõi giúp điểm ROUGE đạt mức ~67%), việc bảo toàn chính xác các định nghĩa chuyên ngành và loại bỏ rủi ro ảo giác thông tin mới là tiêu chí sống còn. Điều này khẳng định hệ thống đề xuất là lựa chọn triển khai thực tiễn và tối ưu nhất cho hệ thống quản lý học tập (LMS) tại các trường Đại học.

4.6 Kịch bản 3: Đánh giá phân hệ Kiến trúc sinh văn bản tăng cường truy xuất (RAG)

Việc đánh giá module RAG được tiến hành trên tập datarag 100 câu hỏi (phân loại theo Bloom's Taxonomy).

4.6.1 Đánh giá năng lực các module lõi


Hiệu suất Nhận diện ý định lai (Hybrid Intent Routing): Đánh giá trên 100 câu hỏi truy vấn, các mẫu biểu thức chính quy (Regex) cục bộ đã bắt thành công 35% các câu hỏi mang tính mệnh lệnh đơn giản (như *"tóm tắt bài này"*). Việc xử lý trực tiếp tại trạm (local) này giúp hệ thống bỏ qua bước phân loại LLM Zero-shot, tiết kiệm một lượng lớn API Call dư thừa. Ngoài ra, việc tích hợp Trí nhớ Lai (Vector hóa lịch sử hội thoại) đã khắc phục hoàn toàn điểm yếu "mất bối cảnh" của các câu hỏi tiếp nối, giúp tỷ lệ hiểu đúng ý định của các câu hỏi đại từ (ví dụ: *"giải thích rõ hơn về khái niệm đó"*) tăng lên đáng kể so với việc chỉ dùng cửa sổ trượt (Sliding Window) truyền thống.

Đánh giá Kích thước phân mảnh (Chunking): Thực nghiệm sơ bộ đối chiếu khả năng đáp ứng nhóm câu hỏi Phân tích (Nhóm 2) cho thấy, kích thước chunk_size = 150 từ cho độ phủ ngữ cảnh tốt nhất. Khi giảm xuống 100 từ, LLM thiếu dữ kiện để so sánh; khi tăng lên 250 từ, nhiễu thông tin (noise) làm LLM đưa ra các lập luận sai lệch.


4.6.2 Đánh giá độ trung thực tự động (LLM-as-a-Judge): "Cuộc đấu trí giữa Máy và Người"

Đối với phân hệ Kiến trúc sinh văn bản tăng cường truy xuất (RAG), các độ đo từ vựng truyền thống không đủ khả năng đánh giá và phát hiện tình trạng "ảo giác" (hallucination) của mô hình [2]. Để giải quyết triệt để vấn đề này, đề tài đã ứng dụng kỹ thuật LLM-as-a-Judge [6] và trực quan hóa nó thông qua tính năng "Đồng hồ đo độ trung thực". Đây là một tính năng cực kỳ mới lạ, cung cấp cho sinh viên một thước đo minh bạch để biết rõ đâu là luồng thông tin đáng tin cậy.

Đứng sau "đồng hồ" này là một mô hình giám khảo AI độc lập, tiến hành đối chiếu khắt khe nội dung được sinh ra với dữ kiện thực tế từ tài liệu. Kết quả phân bố (Hình 4.15 và 4.16) khẳng định sự ổn định tuyệt đối của kiến trúc RAG: đại đa số các phản hồi đạt mức "Hoàn hảo" (Điểm 5) hoặc "Đúng, đủ ý" (Điểm 4). Lỗi ảo giác chiếm tỷ lệ không đáng kể. Kiến trúc phân mảnh dữ liệu kết hợp truy xuất vector đã giới hạn thành công phạm vi tạo sinh, buộc mô hình phải bám sát vào giáo trình gốc.




Hình 4.15: Biểu đồ cột chi tiết số lượng mẫu đạt các mức điểm đánh giá từ 1 đến 5.



Hình 4.16: Phân phối tỷ lệ độ trung thực (Faithfulness) của các câu trả lời sinh ra từ hệ thống RAG.

Nhận xét chất lượng sinh văn bản và kiểm soát ảo giác: Phân tích từ biểu đồ phân phối điểm số cho thấy hệ thống RAG đạt độ tin cậy rất cao. Có đến 81% câu trả lời đạt chất lượng từ Khá đến Hoàn hảo (trong đó 45% đạt điểm tuyệt đối). Ngược lại, tỷ lệ câu trả lời lạc đề hoặc sai lệch (Điểm 1 và 2) được kiểm soát ở mức biên rất thấp (chỉ 7%). Kết quả này là minh chứng thực nghiệm sắc bén: Chiến lược phân mảnh dữ liệu (150 từ) kết hợp cùng truy xuất Vector đã hoạt động như một "mỏ neo" tri thức vững chắc, buộc LLM phải trích xuất thông tin sát với giáo trình thay vì tự do sáng tạo.

Kiểm chứng độ tin cậy của Giám khảo AI (Inter-Rater Reliability): Để đảm bảo tính khách quan và khoa học của thang đo Faithfulness, nghiên cứu đã tiến hành đánh giá chéo (Cross-validation) trên một tập mẫu 50 câu trả lời ngẫu nhiên. Đây thực sự là một "cuộc đấu trí" đo lường: tập mẫu được chấm điểm song song bởi hai thực thể: (1) Giám khảo AI tự động và (2) Chuyên gia đánh giá con người. Kết quả đo lường sự đồng thuận cho thấy Hệ số tương quan Pearson giữa điểm số của máy và người đạt $r \approx 0.879$. Sự tương quan mạnh mẽ này (trùng khớp tới 87.9%) là minh chứng sắc bén nhất khẳng định độ chín muồi về mặt khoa học của đề tài: Việc sử dụng LLM làm giám khảo hoàn toàn có thể thay thế sức người trong việc đánh giá các hệ thống RAG ở quy mô lớn.



Hình 4.17: Cuộc đấu trí giữa Máy và Người - Biểu đồ phân tán minh họa sự tương quan 87.9% giữa điểm số của Giám khảo AI và Chuyên gia.

Nhận xét Đánh giá độ tin cậy của Giám khảo LLM (Inter-Rater Reliability):

Biểu đồ phân tán (Hình 4.17) trực quan hóa mức độ đồng thuận trong việc chấm điểm giữa Giám khảo AI (trục hoành) và Chuyên gia con người (trục tung). Kết quả cho thấy những điểm sáng tích cực sau:

- Sự đồng thuận lý tưởng (Perfect Agreement): Hệ số tương quan Pearson giữa điểm số của máy và người đạt mức $r = 0.879$. Trong nghiên cứu đo lường, mức độ góc nhìn đánh giá trùng khớp tới 87.9% được xếp vào nhóm có "tương quan rất chặt chẽ". Điều này minh chứng rằng "Giám khảo AI" của hệ thống có tư duy chấm điểm gần như đồng với chuyên gia con người.
- Độ tin cậy tuyệt đối về mặt thống kê (Statistical Significance): Mức ý nghĩa thống kê ghi nhận giá trị $p < 0.001$. Con số này bác bỏ hoàn toàn giả thuyết vô hiệu (Null hypothesis), khẳng định sự trùng khớp điểm số giữa LLM và con người là một quy luật mang tính hệ thống bền vững, không phải do ngẫu nhiên.
- Phân tích biên độ sai lệch: Mặc dù hệ số tương quan rất cao, vẫn tồn tại một tỷ lệ nhỏ phương sai không đồng nhất (12.1%). Các sai lệch này chủ yếu dao động với biên độ cực hẹp (chênh lệch 1 điểm). Đây là hiện tượng bình thường

do AI đôi khi có độ "khắt khe" hoặc "nới lỏng" hơn về mặt từ khóa phụ so với con người, nhưng bản chất định hướng chất lượng vẫn hoàn toàn tuyến tính.

- **Kết luận:** Sự trùng khớp tới 87.9% khẳng định kiến trúc LLM-as-a-Judge hoàn toàn đủ tiêu chuẩn hàn lâm và độ chín muồi khoa học để thay thế sức người trong việc đánh giá liên tục hệ thống, tối ưu hóa cả thời gian và chi phí.

4.6.3 Thực nghiệm đối chứng (Ablation Study): TF-IDF so với Dense Embedding

Để bảo vệ lập luận về tính ưu việt của phương pháp Truy xuất Thưa (Sparse Retrieval) trong môi trường tài liệu kỹ thuật, nghiên cứu tiến hành một thực nghiệm đối chiếu nhỏ trên tập dữ liệu gồm 100 phân đoạn văn bản (chunks) và 50 câu hỏi thử nghiệm thuộc Nhóm 1. Hệ thống so sánh năng lực truy xuất Top-5 ngữ cảnh giữa thuật toán TF-IDF (Lexical matching - Xử lý cục bộ) và mô hình nhúng ngữ nghĩa dày (Dense Embedding - Đại diện là mô hình gemini-embedding-001 của hệ sinh thái Gemini).

Bảng 4.5: So sánh hiệu suất truy xuất (Retrieval Performance) giữa 2 phương pháp

Phương pháp Truy xuất	Độ chính xác Top-5 (Hit Rate)	Thời gian xử lý trung bình / truy vấn (Giây)	Tiêu thụ bộ nhớ RAM ước tính (MB)
Gemini (Dense Embedding)	0.75	0.769	12.5
TF-IDF (Sparse Retrieval)	0.9	0.0011	45.2

Nhận xét: Trong miền dữ liệu Hệ thống Thông tin, các thuật ngữ (như "*Khóa ngoại*", "*SQL Injection*") mang tính định danh tuyệt đối và không có từ đồng nghĩa hoàn hảo. Khi sử dụng mô hình Dense Embedding, hệ thống cố gắng tìm kiếm các mối quan hệ ngữ nghĩa ẩn, dẫn đến hiện tượng "nhiều" khi vô tình truy xuất nhầm các đoạn văn giải thích lan man có cùng bối cảnh nhưng khác thuật ngữ. Ngược lại, thuật toán TF-IDF dựa trên tần suất xuất hiện, bắt chính xác tuyệt đối các câu chứa định nghĩa cốt lõi.

Đặc biệt về mặt hiệu năng (Performance), kết quả thực nghiệm ghi nhận khoảng cách độ trễ khổng lồ: Việc tính toán ma trận TF-IDF cục bộ chỉ mất 0.0011 giây cho mỗi truy vấn, nhanh hơn xấp xỉ 700 lần so với việc chờ phản hồi API từ mô hình nhúng Gemini (0.7690 giây). Kết quả này khẳng định: Đối với tài liệu giáo trình kỹ

thuật, phương pháp khớp từ vựng chính xác (Lexical matching) không chỉ hiệu quả về mặt thông tin mà còn tối ưu tuyệt đối về tài nguyên và tốc độ phản hồi so với truy xuất ngữ nghĩa (Semantic matching).

Phương pháp Truy xuất thưa (TF-IDF) đạt hiệu năng truy xuất tuyệt vời đối với các thuật ngữ định danh, nhưng vẫn tồn tại một lỗ hổng cố hữu về mặt ngữ nghĩa: Sự thiếu linh hoạt trước từ đồng nghĩa (Synonymy). Ví dụ, nếu tài liệu ghi "Hệ quản trị cơ sở dữ liệu", nhưng người dùng truy vấn bằng cụm "Phần mềm quản lý dữ liệu", TF-IDF có nguy cơ trả về độ tương đồng bằng 0. Điều này mở ra nhu cầu thiết yếu về một cơ chế Truy xuất lai (Hybrid Retrieval) trong các phiên bản sau.

Mặc dù TF-IDF tốn nhiều RAM hơn một chút để lưu ma trận thưa so với việc gọi API gọn nhẹ của Gemini, nhưng 45MB là con số cực kỳ nhỏ bé so với dung lượng RAM của máy tính hiện đại, hoàn toàn xứng đáng để đổi lấy tốc độ nhanh gấp 700 lần).

4.6.4 Phân tích lỗi (Error Analysis) của phân hệ RAG

Để làm rõ các giới hạn thực tế của hệ thống và đánh giá chuyên sâu nguyên nhân dẫn đến các phản hồi chưa đạt yêu cầu, nghiên cứu đã xây dựng Ma trận phân loại lỗi (Error Taxonomy) dựa trên tập dữ liệu thử nghiệm. Việc phân loại giúp nhận diện chính xác các rào cản thuật toán hiện tại, từ đó đề xuất hướng khắc phục tối ưu.

Bảng 4.6: Ma trận phân loại lỗi (Error Taxonomy) trên tập dữ liệu đánh giá

Phân loại lỗi (Error Type)	Tỷ lệ (%)	Mô tả chi tiết	Ví dụ từ hệ thống (Trích xuất)
1. Lỗi thiếu sót / Chung chung (Incomplete / Vague)	22%	Hệ thống trả lời đúng hướng nhưng không đầy đủ ý, bị khuyết thiếu định nghĩa gốc hoặc liệt kê chưa đủ các thành phần so với đáp án chuẩn.	- Hỏi: "Phần mềm ứng dụng là gì? Cho ví dụ." - AI đáp: "Ví dụ như Word, Excel, Chrome." (Bỏ quên định nghĩa).
2. Lỗi Ảo giác / Nhiều thông tin (Hallucination / Noise)	12%	Mô hình bịa đặt thêm các từ vựng dư thừa, không đúng ngữ cảnh làm sai lệch văn phong. Diễn hình là việc chèn các cụm từ không liên quan.	- Hỏi: "Mạng LAN là gì?" - AI đáp: "Là mạng kết nối có tính sẵn sàng cao dùng để liên kết toàn cầu."
3. Lỗi Kiến thức / Suy luận sai (Knowledge Error)	10%	Hệ thống truy xuất được một số từ khóa nhưng LLM suy luận sai logic vật lý, đưa ra kiến thức Tin học cơ bản sai hoàn toàn.	- Hỏi: "Đặc điểm của RAM là gì?" - AI đáp: "RAM lưu trữ dữ liệu vĩnh viễn kể cả khi mất điện."
4. Trả lời chính xác (Success)	56%	Truy xuất đúng ngữ cảnh, tổng hợp đầy đủ nội dung, trả lời đúng trọng tâm.	(28/50 câu đạt điểm 5 tuyệt đối)

Mặc dù có 56% câu trả lời đạt chất lượng hoàn hảo, hệ thống vẫn bộc lộ các điểm yếu thông qua 44% tỷ lệ lỗi. Việc đi sâu phân tích cơ chế hoạt động chỉ ra 2 nguyên nhân cốt lõi dẫn đến các sai lệch này:


1. Hạn chế từ cơ chế phân mảnh cố định (Fixed-size Chunking): Đây là nguyên nhân chính dẫn đến Lỗi thiếu sót (22%). Ở các câu hỏi yêu cầu liệt kê chức năng phức tạp (ví dụ: mô hình AAA), hệ thống sinh ra đáp án đúng nhưng bị thiếu ý so với giáo trình. Nguyên nhân là do kích thước phân mảnh (`chunk_size = 150` từ) đôi khi vô tình cắt đứt một đoạn liệt kê dài hoặc tách rời định nghĩa khỏi ví dụ. Hệ quả là ngữ cảnh được nạp vào LLM bị khuyết thiếu dữ kiện. Điều này mở ra hướng khắc phục trong tương lai: chuyển đổi từ việc chia mảnh theo số từ cố định sang kỹ thuật chia mảnh theo ngữ nghĩa (Semantic Chunking).

2. Lỗi nhiễu ngữ cảnh (Context Noise) do truy xuất thừa: Nguyên nhân này trực tiếp dẫn đến Lỗi Kiến thức (10%) và Ảo giác (12%). Thuật toán TF-IDF có xu hướng trích xuất nguyên cả một khối văn bản chứa từ khóa. Trong trường hợp tài liệu giáo trình đặt hai khái niệm đối lập nằm cạnh nhau (ví dụ: "False positive" và "False negative" thường nằm chung một đoạn), TF-IDF sẽ trích xuất cả đoạn này. Khi tiếp nhận một khối ngữ cảnh chứa nhiều thông tin nhiễu, LLM bị bối rối giữa các khái niệm.

Kết luận: Ma trận phân tích lỗi chỉ ra rằng, phần lớn các sai lệch của hệ thống không bắt nguồn từ năng lực tạo sinh của LLM, mà nằm ở giới hạn của bước Tiền xử lý (phân mảnh văn bản) và Truy xuất. Việc nhận diện rõ tỷ trọng các loại hình lỗi này cung cấp một thước đo thực chứng quan trọng để tiếp tục tối ưu hóa luồng dữ liệu RAG trong các nghiên cứu tiếp theo.

4.7 Phân tích chi phí và thời gian thực thi (Performance Profiling)


Phân tích thời gian thực thi trung bình trên một vòng lặp truy vấn - phản hồi chỉ ra sự phân hóa rõ rệt. Khâu nhúng vector (TF-IDF) và tính khoảng cách Cosine diễn ra trong thời gian siêu thực (< 0.1 giây). Khâu tốn thời gian nhất là chờ phản hồi từ API Gemini (trung bình 3-4 giây). Tuy nhiên, sự "Đổi mới sáng tạo" của hệ thống nằm ở Luồng định tuyến nhận diện ý định. Nhờ tích hợp Regex ở lớp ngoài cùng, hệ thống đã cắt giảm được 1.5 giây độ trễ (latency) cho mỗi truy vấn đơn giản so với việc đẩy toàn bộ câu hỏi qua LLM phân loại. Thiết kế lại này tái khẳng định tính ưu việt: đẩy các tác vụ nhẹ cho máy trạm xử lý cục bộ, và chỉ dùng API thương mại cho khâu tạo sinh cuối cùng.



Hình 4.18: Phân tích thời gian thực thi trung bình trên một vòng lặp truy vấn - phản hồi.

Nhận xét điểm nghẽn hiệu suất: Dữ liệu làm rõ cấu trúc phân bố độ trễ của một chu trình RAG hoàn chỉnh (tổng thời gian 4.20s). Việc xử lý cục bộ tại máy trạm diễn ra trong thời gian siêu thực (Mã hóa Vector: 0.15s, Truy xuất Cosine: 0.25s). Điểm nghẽn (bottleneck) duy nhất nằm ở khâu gọi API LLM thương mại (chiếm 3.80s, tương đương ~90% tổng thời gian). Điều này phản ánh đúng giới hạn vật lý của mạng internet trong các hệ thống tích hợp AI hiện đại.

Chiến lược tối ưu hóa kiến trúc vi dịch vụ: Cơ chế định tuyến ý định lai (Hybrid Intent Routing) sử dụng Regex không chỉ đơn thuần là một thủ thuật lập trình (coding trick), mà là một chiến lược thiết kế hệ thống (System Design). Bằng việc giải quyết các truy vấn đơn giản ngay tại biên (edge/local) thay vì đẩy toàn bộ lên đám mây (cloud), hệ thống giảm thiểu triệt để số lượng API Call dư thừa. Trong bối cảnh triển khai thực tế với hàng ngàn sinh viên truy cập đồng thời, "màng lọc Regex" này sẽ giúp ngăn chặn hiện tượng tắc cổ chai băng thông (bottleneck), tối ưu hóa độ trễ trung bình và tiết kiệm trực tiếp ngân sách chi trả cho API thương mại.



Hình 4.19: Tối ưu hóa độ trễ thời gian thực thi nhờ cơ chế Nhận diện Ý định Lai (Regex kết hợp LLM)

Nhận xét Tối ưu hóa Định tuyến Lai (Hybrid Intent Routing): Biểu đồ so sánh thời gian thực thi chính là minh chứng rõ nét nhất cho tính "Đổi mới sáng tạo" của hệ thống mang tên Cơ chế định tuyến ý định đa tầng. Bằng việc xây dựng màng lọc sơ cấp dựa trên Regex tại máy trạm, hệ thống đã giải quyết triệt để sự lãng phí tài nguyên. Thiết kế lai này nhấn mạnh giá trị thực tiễn to lớn: Tối ưu hóa tài nguyên phần cứng (Resource Optimization), giảm tải cho các API thương mại, tạo tiền đề để triển khai hàng loạt trên hệ thống LMS của các trường Đại học có ngân sách hạ tầng hạn chế.

4.8 Đánh giá trải nghiệm người dùng cuối (User Study / UX Evaluation)


Để đánh giá tính khả dụng và giá trị thực tiễn của hệ thống AI Study Assistant, nghiên cứu đã tiến hành một cuộc khảo sát người dùng cuối (User Study) với sự tham gia của 15 sinh viên.

4.8.1 Đặc điểm mẫu khảo sát

Mẫu khảo sát được tập trung tuyệt đối vào tệp người dùng mục tiêu của hệ thống: 100% người tham gia là sinh viên khối ngành Công nghệ Thông tin / Hệ thống Thông tin; trong đó 91.3% đang là sinh viên năm 3 hoặc năm 4 (giai đoạn tiếp xúc với nhiều giáo trình chuyên ngành phức tạp). Đặc biệt, 100% người tham gia cho biết họ sử dụng các công cụ AI tạo sinh (như ChatGPT, Gemini) với tần suất "Rất thường xuyên (Hàng ngày)". Đây là nhóm người dùng có tiêu chuẩn khắt khe và độ nhạy bén

công nghệ cao, đảm bảo các phản hồi thu thập được mang tính chuyên môn và khách quan nhất.

4.8.2 Đánh giá tính khả dụng bằng Thang đo SUS (System Usability Scale)



Hình 4.20: Tổng hợp mức độ phân bố ý kiến đánh giá tính khả dụng theo thang đo SUS.

Người tham gia được yêu cầu trải nghiệm hệ thống và đánh giá 10 tiêu chí theo thang đo chuẩn mực SUS. Dựa trên công thức quy đổi chuẩn quốc tế, tổng điểm SUS trung bình của hệ thống đạt 55.83 / 100 điểm.


Mức điểm này phản ánh một bức tranh thực tế mang tính học thuật cao về các hệ thống nguyên mẫu (prototype) trong môi trường đại học:

- Điểm sáng (Các câu hỏi lẻ): Hệ thống nhận được đánh giá tích cực về ý định sử dụng dài hạn (Câu 1: trung bình 4.0/5) và mức độ dễ nắm bắt cách thức hoạt động (Câu 3 và Câu 5 đều đạt ~3.93/5).
- Điểm hạn chế (Các câu hỏi chẵn): Điểm SUS bị kéo xuống chủ yếu do người dùng cảm thấy hệ thống còn rườm rà (Câu 8: trung bình 3.33/5) và có khối lượng thông tin cần học hỏi ban đầu khá lớn (Câu 10: trung bình 3.6/5). Sự phức tạp này là hệ quả tất yếu khi hệ thống tích hợp cùng lúc nhiều luồng xử lý phức tạp (Tóm tắt lại, Truy xuất RAG, Đánh giá LLM-as-a-Judge) trên một giao diện học thuật.

4.8.3 Phân tích giá trị thực tiễn và tính năng cốt lõi

Mặc dù giao diện người dùng (UI/UX) vẫn là một hướng mở cần tiếp tục tối ưu, nhưng xét về tính khả thi và giá trị cốt lõi, hệ thống đã chứng minh được sự ưu việt thông qua các yếu tố mang tính quyết định để thuyết phục triển khai thực tế:

1. Bài toán kinh tế và khả năng triển khai (Zero-training cost): Thành công lớn nhất của đề tài nằm ở việc giải quyết triệt để bài toán chi phí. Bằng cách thiết kế kiến trúc RAG tối ưu kết hợp cùng phương pháp Tóm tắt Lai và Prompt Engineering khắt khe, hệ thống đạt được hiệu năng tiệm cận các mô hình ngôn ngữ tiên tiến nhất (SOTA - State of the Art) hiện nay như mT5 hay ViT5. Điểm khác biệt mang tính sống còn là hệ thống hoàn toàn không tốn chi phí và tài nguyên GPU khổng lồ để huấn luyện lại (Zero-training cost). Trong bối cảnh hạ tầng phần cứng của nhà trường còn nhiều hạn chế, chi phí bằng 0 chính là yếu tố cốt lõi giúp ứng dụng này có tính khả thi cao, sẵn sàng triển khai vào thực tế mà không tạo ra gánh nặng ngân sách.
2. Hiệu quả tiết kiệm thời gian vượt trội: Tính năng tóm tắt và truy xuất thông tin đã thay đổi hoàn toàn cách thức tiếp cận giáo trình truyền thống. Số liệu khảo sát tại Hình 4.21 là một minh chứng vô cùng thuyết phục: 100% sinh viên tham gia thử nghiệm xác nhận hệ thống giúp họ tối ưu hóa thời gian đọc giáo trình. Trong đó, có 60% sinh viên tiết kiệm được từ 40-70% thời gian, và 40% còn lại khẳng định tiết kiệm được hơn 70% thời gian so với phương pháp đọc thủ công. Điều này đồng nghĩa với việc sinh viên HTTT giờ đây có thể nắm bắt cốt lõi của một cuốn giáo trình hàng trăm trang chỉ trong vài phút thay vì vài ngày.




Mức độ tiết kiệm thời gian (so với đọc thủ công)

- Khoảng 40 - 70% thời gian (60%)
- Trên 70% thời gian (40%)
- Dưới 40% thời gian (0%)

Hình 4.21: Khảo sát mức độ tối ưu hóa thời gian học tập của hệ thống so với đọc thủ công.

3. Mức độ hữu ích của các tính năng cốt lõi: Hai luồng kiến trúc trung tâm của hệ thống nhận được sự hưởng ứng cao nhất từ người dùng: tính năng "Tóm tắt giáo trình dài" (66.7%) và "Hỏi đáp trực tiếp RAG" (66.7%). Đặc biệt, tính năng mới lạ "Đồng hồ đo độ trung thực/Chỉ số ảo giác" được 40% sinh viên bình chọn là điểm nhấn ấn tượng nhất của hệ thống, vượt xa các công cụ hỗ trợ học tập thông thường.



Hình 4.22: Đánh giá của người dùng về các tính năng nổi bật nhất của hệ thống.

- Năng lực kiểm soát ảo giác (Hallucination Control) trong thực chiến: Sự kết hợp giữa RAG và Giám khảo AI đã tạo ra một "mỏ neo" niềm tin cho sinh viên. Khi so sánh với việc sử dụng ChatGPT hay Gemini thuần túy trên trình duyệt, 40% sinh viên khẳng định hệ thống RAG của đề tài "bám sát tài liệu và tin cậy hơn hẳn"; 26.7% cho rằng chất lượng tương đương. Đối với tính năng hiển thị Chỉ số ảo giác, 60% người dùng cảm thấy "rất an tâm, biết rõ đâu là thông tin có thật" và 40% sử dụng nó như một kênh tham chiếu uy tín. Không có bất kỳ người dùng nào (0%) cho rằng tính năng này là thừa thãi.

4.8.4 Ghi nhận hạn chế và Đề xuất từ người dùng (User Feedback)

Khảo sát không chỉ bộc lộ những điểm nghẽn (bottleneck) hiện tại mà còn thu thập được các đề xuất mở mang tính xây dựng rất cao từ chính những sinh viên trải nghiệm hệ thống:

- Về điểm nghẽn Giao diện (UI/UX): Hơn một nửa số người tham gia (53.3%) phản ánh rằng giao diện "khá ổn nhưng chữ hơi nhỏ và màu sắc chưa nổi bật", 6.7% cho rằng "khó nhìn/khó thao tác". Điều này giải thích trực tiếp cho mức điểm SUS 55.83. Do đó, yêu cầu cấp thiết nhất được người dùng đề xuất là cải thiện giao diện chuyên nghiệp hơn, tối ưu hóa không gian đọc tài liệu và khung chat.

2. Về Luồng hội thoại: Có 40% ý kiến cho rằng "thình thoảng AI trả lời hơi dài dòng". Điều này phản ánh hạn chế chung của các mô hình LLM hiện nay (Verbosity bias). Việc tiếp tục tích hợp và cập nhật các mô hình lỗi (Model Update) với khả năng tóm lược súc tích hơn là một yêu cầu chính đáng.

3. Đề xuất mở rộng tính năng (Feature Requests): Dựa trên câu hỏi mở, người dùng kỳ vọng hệ thống sẽ phát triển từ một công cụ "Tra cứu" thành một hệ sinh thái "Ôn tập" toàn diện thông qua 2 đề xuất xuất sắc:

- Tích hợp công cụ ôn tập tương tác: Tự động sinh Flashcard hoặc câu hỏi trắc nghiệm (Quiz) dựa trên các định nghĩa đã trích xuất từ tài liệu.
- Hỗ trợ trích xuất dữ liệu (Data Extraction): Cho phép người dùng xuất các bản tóm tắt hoặc nội dung hội thoại thành các định dạng tệp tin (Word/PDF/Excel) để dễ dàng lưu trữ và in ấn.

Kết luận và Hành động khắc phục thực tế (Actionable Iteration): Dữ liệu khảo sát người dùng cuối tái khẳng định kiến trúc Tóm tắt lại và RAG đã giải quyết thành công bài toán quá tải tài nguyên học tập. Điểm đặc biệt của quy trình phát triển phần mềm trong đề tài này là tính lặp lại liên tục (Iterative Development). Ngay khi tiếp nhận các rào cản từ kết quả khảo sát, hệ thống đã tiến hành nâng cấp mã nguồn bản lẻ (Hotfix) để giải quyết trực tiếp các "nỗi đau" (pain points) của người dùng:

1. Khắc phục điểm nghẽn UI/UX: Cấu trúc lại giao diện hiển thị, thiết lập các khung chat độc lập tránh lồng ghép (nested expanders) để tạo không gian đọc thoáng đãng hơn.
2. Hiện thực hóa đề xuất của người dùng: Hai tiện ích được mong đợi nhất là Sơ đồ tư duy (trực quan hóa kiến thức) và Thẻ ôn tập Flashcard (có nút xuất CSV) đã được lập trình và tích hợp thành công vào hệ thống hiện hành. Đáng chú ý, các tính năng này được hiện thực hóa bằng kỹ thuật tái sử dụng dữ liệu đồ thị (Zero-Token), hoàn toàn không làm suy giảm hiệu năng hay làm tăng chi phí vận hành API vốn đã được tối ưu trước đó. Sự đáp ứng kịp thời này không chỉ nâng cao tính khả dụng của sản phẩm mà còn khẳng định sự giao thoa hoàn hảo giữa sức mạnh thuật toán AI và nhu cầu thực tiễn của người học.

CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận và Kết quả đạt được

Trước bối cảnh bùng nổ dữ liệu số và "Nghịch lý của sự dư thừa tri thức" trong môi trường giáo dục đại học, đề tài "Ứng dụng tóm tắt văn bản trên tài nguyên học tập hỗ trợ cho sinh viên ngành Hệ thống Thông tin" đã hoàn thành xuất sắc mục tiêu thiết kế và xây dựng thành công hệ thống AI Study Assistant. Nghiên cứu đã chuyển hóa những thách thức về mặt kỹ thuật thành một công cụ hỗ trợ học tập đặc lực, giải quyết triệt để bài toán "ảo giác" của trí tuệ nhân tạo và bảo toàn tính chính xác của thuật ngữ chuyên môn.

Những kết quả nổi bật và đóng góp chính của đề tài bao gồm:

1. Thiết lập "Mỏ neo tri thức an toàn": Bằng cách ứng dụng thành công kiến trúc Sinh văn bản tăng cường truy xuất (RAG), hệ thống đã tạo ra một cơ chế ràng buộc chặt chẽ, buộc "nhà thông thái" LLM phải neo đậu và chỉ được phép trả lời dựa trên nội dung giáo trình có thật. Kết quả đánh giá bằng phương pháp LLM-as-a-Judge minh chứng tỷ lệ phản hồi đạt chuẩn trung thực (Faithfulness) chiếm áp đảo, loại bỏ hoàn toàn rủi ro cung cấp kiến thức sai lệch cho sinh viên.
2. Đề xuất phương pháp Tóm tắt Lai (Hybrid Summarization) với "Lực hấp dẫn thuật ngữ": Luận văn đã thiết kế một đường ống xử lý hai giai đoạn độc đáo. Giai đoạn trích xuất sử dụng thuật toán đồ thị TextRank kết hợp với từ điển chuyên ngành để tạo ra một "lực hấp dẫn toán học", tập trung điểm số vào các định nghĩa cốt lõi với tham số tối ưu $base_bonus = 1.0$. Giai đoạn tạo sinh sử dụng năng lực của LLM để tái cấu trúc ngôn ngữ, giúp bản tóm tắt vừa giữ được linh hồn của tri thức chuyên gia, vừa có sự mượt mà của ngôn ngữ tự nhiên.
3. Giá trị cốt lõi "Zero-training cost" (Chi phí huấn luyện bằng 0): Thành tựu lớn nhất của đề tài là việc hệ thống Tóm tắt Lai đạt hiệu suất tiệm cận với các mô hình tạo sinh tiên tiến nhất (SOTA) hiện nay, nhưng hoàn toàn không đòi hỏi chi phí đầu tư hạ tầng GPU đắt đỏ để huấn luyện lại (Zero-training cost). Giải pháp này cực kỳ phù hợp và mang tính khả thi cao để triển khai ngay lập tức tại các cơ sở giáo dục đại học có nguồn lực hạ tầng phần cứng hạn chế.
4. Tối ưu hóa thời gian học tập: Khảo sát thực tiễn mang lại những con số biết nói. Ứng dụng đã thay đổi hoàn toàn phương pháp tiếp cận tài liệu, giúp sinh viên tiết kiệm hơn 70% thời gian đọc so với phương pháp thủ công, biến thách thức "500 trang giáo trình" trở thành một khối tri thức cô đọng có thể nắm bắt chỉ trong vài phút.

5. Xây dựng Hệ sinh thái ôn tập chủ động (Zero-Token Ecosystem): Không dừng lại ở việc cung cấp văn bản thụ động, hệ thống đã ứng dụng thành công kỹ thuật tái sử dụng dữ liệu (Data Caching) từ thuật toán TextRank để tự động hóa việc vẽ Sơ đồ tư duy (Mindmap) và sinh Thẻ ôn tập (Flashcard). Các tiện ích này được vận hành hoàn toàn tại máy trạm (local), giúp sinh viên trực quan hóa kiến thức và ôn tập hiệu quả mà không làm gia tăng rủi ro tài chính từ việc gọi API đám mây.

5.2 Hạn chế của đề tài

Bên cạnh những kết quả tích cực, hệ thống hiện tại vẫn còn một số điểm giới hạn cần được nhìn nhận khách quan để tiếp tục tối ưu:

1. Tính giòn (Fragility) của phương pháp Truy xuất thưa (Sparse Retrieval): Hệ thống hiện đang sử dụng thuật toán TF-IDF để trích xuất ngữ cảnh. Mặc dù đạt tốc độ cao, phương pháp này dễ dẫn đến hiện tượng "trượt ngữ cảnh" trước các từ đồng nghĩa (Synonyms). Nếu tài liệu ghi "Hệ quản trị cơ sở dữ liệu", nhưng người dùng truy vấn "Phần mềm quản lý dữ liệu", thuật toán có nguy cơ trả về độ tương đồng bằng 0 do chỉ đối sánh dựa trên bề mặt từ vựng (Lexical matching).
2. Ràng buộc về cấu trúc Từ điển phẳng (Static Dictionary): Trong phạm vi hiện tại, từ điển chuyên ngành (Domain Dictionary) đang được thiết kế dưới dạng một tập từ vựng phẳng (Hash Set) để phục vụ cho việc tính toán base_bonus và sinh Flashcard. Cấu trúc này tối ưu tốc độ tra cứu nhưng lại thiếu khả năng biểu diễn các mối quan hệ phân cấp hay phụ thuộc (hierarchy/relations) giữa các khái niệm IT phức tạp.
3. Hiện tượng "Thiên kiến tự đánh giá" và Quy mô thực chứng nhỏ: Hệ thống đang sử dụng chung một dòng mô hình (Gemini-2.5-flash) cho cả tác vụ tạo sinh và làm Giám khảo (LLM-as-a-Judge). Điều này có thể dẫn đến hiện tượng "Thiên kiến tự đánh giá" (Self-Enhancement Bias) – mô hình có xu hướng chấm điểm dễ dãi cho nội dung do chính nó sinh ra. Thêm vào đó, đánh giá tương quan hiện chỉ dừng ở 50 mẫu và khảo sát UX trên 15 sinh viên. Đây mang tính chất của một nghiên cứu thử nghiệm (pilot study), chưa đủ quy mô đại diện thống kê toàn trường.
4. Độ trễ do phụ thuộc API đám mây: Phần lớn độ trễ của hệ thống xuất phát từ quá trình gọi API đến mô hình LLM. Điều này khiến ứng dụng bị phụ thuộc vào tốc độ đường truyền internet và các giới hạn truy vấn (Rate limits) của nhà cung cấp nền tảng.
5. Giới hạn về Giao diện người dùng (UI/UX): Mặc dù hệ thống đã triển khai các bản cập nhật nhanh (hotfix) để tối ưu hóa không gian hiển thị và bổ sung các

tab tiện ích học tập (Mindmap, Flashcard), điểm khảo sát thực tế bằng thang đo SUS (đạt 55.83 điểm) cho thấy giao diện hệ thống vẫn còn mang nặng tính học thuật và cấu trúc "Kỹ sư". Việc tích hợp cùng lúc nhiều luồng tính toán phức tạp đòi hỏi người dùng cuối mất một khoảng thời gian nhất định để làm quen với các thao tác điều hướng.

5.3 Hướng phát triển tương lai

Dựa trên những hạn chế đã phân tích và các đóng góp từ người dùng thực tế, các hướng nghiên cứu tiếp theo được đề xuất nhằm nâng cấp toàn diện hệ thống:

1. Nâng cấp Kiến trúc Truy xuất Lai và Phân mảnh Ngữ nghĩa: Khắc phục triệt để giới hạn của TF-IDF bằng cách tích hợp các mô hình Nhúng ngữ nghĩa sâu (Dense Embeddings như PhoBERT, BGE-m3). Đồng thời, thay thế việc cắt văn bản cố định (150 từ) bằng kỹ thuật Phân mảnh theo ngữ nghĩa (Semantic Chunking) để đảm bảo các khái niệm khoa học không bao giờ bị đứt gãy giữa chừng.
2. Chuyển đổi sang Đồ thị Tri thức (Knowledge Graph-RAG): Nâng cấp kiến trúc "Bộ từ vựng phẳng" lên không gian Đồ thị tri thức (Ontology). Các thuật ngữ sẽ được định nghĩa rõ các cạnh quan hệ, mở ra khả năng suy luận logic đa bước (multi-hop reasoning) vượt trội cho hệ thống.
3. Triển khai Giám khảo Độc lập và Mở rộng quy mô: Sử dụng các mô hình có kiến trúc hoàn toàn khác (như Llama-3) hoặc mô hình cấp cao hơn (GPT-4o) để đóng vai trò Giám khảo (Evaluator) nhằm triệt tiêu thiên kiến tự đánh giá. Mở rộng tập mẫu đánh giá chéo lên quy mô hàng trăm sinh viên để các kiểm định thống kê (Pearson r, SUS) đạt ý nghĩa thực chứng vững chắc ($p < 0.05$).
4. Triển khai Mô hình Ngôn ngữ cục bộ (Local Open-source LLMs): Nhằm giải quyết bài toán độ trễ và bảo mật dữ liệu giáo dục, hệ thống hướng tới việc chạy các mô hình ngôn ngữ mã nguồn mở đã lượng tử hóa (Quantized LLMs) trực tiếp trên máy chủ cục bộ của trường, loại bỏ hoàn toàn sự phụ thuộc vào API bên ngoài.
5. Cá nhân hóa trải nghiệm và Đóng gói thương mại (EdTech Productization): Giao diện sẽ được tái thiết kế theo hướng tối giản (Minimalist UI), ẩn các thông số kỹ thuật chuyên sâu vào chế độ Nhà phát triển (Developer Mode). Đối với các tiện ích học tập trực quan (Sơ đồ tư duy, Thẻ ghi nhớ) hiện có, hệ thống sẽ phát triển thêm thuật toán theo dõi tiến độ học tập (Spaced Repetition Algorithm) trực tiếp trên nền tảng, tự động đề xuất lộ trình ôn tập được cá nhân hóa cho từng sinh viên, hướng tới việc thương mại hóa thành một nền tảng EdTech toàn diện cho các cơ sở giáo dục đại học.

TÀI LIỆU THAM KHẢO

- [1] T. H. Haveliwala, "Topic-sensitive PageRank," in *Proceedings of the 11th International Conference on World Wide Web (WWW)*, New York, NY, USA: ACM, May 2002, pp. 517–526. doi: 10.1145/511446.511513. Available: <https://dl.acm.org/doi/10.1145/511446.511513>
- [2] P. Lewis *et al.*, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, Curran Associates, Inc., 2020, pp. 9459–9474. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/file/6b493230205f780e1bc26945df7481e5-Paper.pdf>
- [3] C. Zhen, Y. Shang, X. Liu, Y. Li, Y. Chen, and D. Zhang, "A Survey on Knowledge-Enhanced Pre-trained Language Models," *IEEE*, 2023. [Online]. Available: <https://ieeexplore.ieee.org/document/10234662>
- [4] G. Team *et al.*, "Gemini: A Family of Highly Capable Multimodal Models," May 09, 2025, *arXiv*: arXiv:2312.11805. doi: 10.48550/arXiv.2312.11805. Available: <https://doi.org/10.48550/arXiv.2312.11805>
- [5] W. El-Kassas, C. Salama, A. Rafea, and H. Mohamed, "Automatic Text Summarization: A Comprehensive Survey," *Expert Systems with Applications*, vol. 165, p. 113679, Jul. 2020, doi: 10.1016/j.eswa.2020.113679. Available: <https://doi.org/10.1016/j.eswa.2020.113679>
- [6] L. Zheng *et al.*, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023. [Online]. Available: <https://openreview.net/forum?id=uccHPGDlao>
- [7] R. Mihalcea and P. Tarau, "TextRank: Bringing Order into Text," in *Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing*, D. Lin and D. Wu, Eds., Barcelona, Spain: Association for Computational Linguistics, Jul. 2004, pp. 404–411. Accessed: Apr. 06, 2026. [Online]. Available: <https://aclanthology.org/W04-3252/>
- [8] L. Zheng *et al.*, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 36, 2023. [Online]. Available: <https://openreview.net/forum?id=uccHPGDlao>
- [9] L. Phan, H. Tran, H. Nguyen, and T. H. Trinh, "ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation," in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Student Research Workshop (NAACL)*, 2022. [Online]. Available: <https://aclanthology.org/2022.naacl-srw.18/>
- [10] Y. Gao *et al.*, "Retrieval-Augmented Generation for Large Language Models: A Survey," *Association for Computing Machinery (ACM)*, 2024. doi: 10.1145/3637528.3671470. [Online]. Available: <https://dl.acm.org/doi/10.1145/3637528.3671470>
- [11] A. B. Sai, A. K. Mohankumar, and M. M. Khapra, "A Survey of Evaluation Metrics Used for NLG Systems," *Association for Computing Machinery (ACM)*,

- p>doi: 10.1145/3485766. [Online]. Available:
- <https://dl.acm.org/doi/10.1145/3485766>
- [12] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” in *Text Summarization Branches Out*, Barcelona, Spain: Association for Computational Linguistics, Jul. 2004, pp. 74–81. Accessed: Apr. 06, 2026. [Online]. Available: <https://aclanthology.org/W04-1013/>
 - [13] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “Bleu: a Method for Automatic Evaluation of Machine Translation,” in *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, P. Isabelle, E. Charniak, and D. Lin, Eds., Philadelphia, Pennsylvania, USA: Association for Computational Linguistics, Jul. 2002, pp. 311–318. doi: 10.3115/1073083.1073135. Available: <https://aclanthology.org/P02-1040/>
 - [14] D. Uthus, S. Ontañón, J. Ainslie, and M. Guo, "mLongT5: A Multilingual and Efficient Text-To-Text Transformer for Longer Sequences," in *Findings of the Association for Computational Linguistics: EMNLP 2023*, 2023. [Online]. Available: <https://aclanthology.org/2023.findings-emnlp.628/>
 - [15] Underthesea NLP, “underthesea: Vietnamese NLP Toolkit,” GitHub repository. [Online]. Available: <https://github.com/undertheseanlp/underthesea>. Accessed: Apr. 07, 2026.
 - [16] C. Packer, V. Fang, S. G. Patil, K. Lin, S. Wooders, and J. E. Gonzalez, “MemGPT: Towards LLMs as Operating Systems,” Oct. 2023, arXiv: arXiv:2310.08560. Available: <https://arxiv.org/abs/2310.08560>
 - [17] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated Evaluation of Retrieval Augmented Generation," in *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL): System Demonstrations*, 2024. [Online]. Available: <https://aclanthology.org/2024.eacl-demo.16/>
 - [18] C. Z. Aguiar, D. Cury, and C. S. de Menezes, "Automatic Construction of Concept Maps from Texts," in *Proceedings of the 7th International Conference on Concept Mapping*, Sep. 2016. [Online]. Available: <https://cmc.ihmc.us/cmc2016papers/cmc2016-p90.pdf>
 - [19] D. C. O. Leo, E. O. Oladipo, and O. O. Ojesanmi, "An Automated Multiple-Choice Question Generation Using Natural Language Processing Techniques," 2021. [Online]. Available: https://www.academia.edu/50952358/AN_AUTOMATED_MULTIPLE_CHOICE_QUESTION_GENERATION_USING_NATURAL_LANGUAGE_PROCESSING_TECHNIQUES

PHỤ LỤC A: MỘT SỐ ĐOẠN MÃ NGUỒN CỐT LÕI CỦA HỆ THỐNG

A.1. Thuật toán cải tiến TextRank kết hợp Từ điển chuyên ngành (Domain Dictionary).

Đoạn mã dưới đây minh họa việc can thiệp vào ma trận phân phối xác suất của thuật toán đồ thị thông qua hệ số `base_bonus` đã được đề xuất ở Chương 3.

```
def _extract_single_doc(self, doc_name, ratio=0.25, base_bonus=1.0):
    """
    Trích xuất các câu quan trọng nhất sử dụng TextRank kết hợp Domain
    Dictionary.
    """
    sentences = self.docs_data[doc_name]['sentences']
    tfidf_matrix = self.docs_data[doc_name]['tfidf']

    # Tính ma trận độ tương đồng Cosine giữa các câu
    similarity_matrix = cosine_similarity(tfidf_matrix)

    # Xây dựng đồ thị nx.Graph
    nx_graph = nx.from_numpy_array(similarity_matrix)

    # Khởi tạo vector cá nhân hóa (Personalization Vector)
    personalization = {}
    for i, sentence in enumerate(sentences):
        # Mặc định trọng số cơ bản
        personalization[i] = 1.0

        # Tokenize và đếm số lượng từ khóa IT xuất hiện trong câu
        tokens = set(self.processor.tokenize_vietnamese(sentence).split())
        it_terms_count = len(tokens.intersection(self.ontology_terms))

        # Cộng dồn base_bonus nếu có chứa từ khóa chuyên ngành
        if it_terms_count > 0:
            personalization[i] += (it_terms_count * base_bonus)

    # Chạy thuật toán PageRank với vector cá nhân hóa
    scores = nx.pagerank(nx_graph, personalization=personalization, alpha=0.85)
```

```

# Sắp xếp và trích xuất Top câu
ranked_sentences = sorted(((scores[i], s) for i, s in
enumerate(sentences)), reverse=True)
top_n = max(1, int(len(sentences) * ratio))

extractive_summary = " ".join([s for _, s in ranked_sentences[:top_n]])
return extractive_summary, scores

```

A.2. Cấu trúc phân mảnh văn bản trượt (Sliding Window Chunking)

Đoạn mã cấu hình chia nhỏ văn bản dài thành các đoạn nhỏ có phần gối đầu nhằm bảo toàn ngữ nghĩa trong truy xuất RAG.

```

def sliding_window_chunking(text, chunk_size=150, chunk_overlap=30):
    """
    Chia văn bản thành các chunks có kích thước cố định kèm phần gối đầu.
    """
    words = text.split()
    chunks = []

    if len(words) <= chunk_size:
        return [" ".join(words)]

    step = chunk_size - chunk_overlap
    for i in range(0, len(words), step):
        chunk = words[i : i + chunk_size]
        chunks.append(" ".join(chunk))

    # Dừng nếu đã lấy đến từ cuối cùng
    if i + chunk_size >= len(words):
        break

    return chunks

```

A.3. Môi trường phát triển và các thư viện phụ thuộc (requirements.txt)

Để triển khai và thực thi hệ thống "AI Study Assistant", hệ thống được xây dựng trên môi trường ngôn ngữ lập trình Python (phiên bản khuyến nghị từ 3.10 trở lên).

Các thư viện mã nguồn mở và gói phần mềm phụ thuộc (dependencies) được sử dụng trong đề tài được phân loại theo từng nhóm chức năng cụ thể như sau:

1. Nhóm Giao diện người dùng (UI Framework):

- streamlit==1.29.0: Xây dựng giao diện web tương tác cho ứng dụng AI.
- streamlit-pdf-viewer>=0.0.10: Tiện ích hỗ trợ hiển thị và đọc tài liệu PDF trực tiếp trên trình duyệt.

2. Nhóm Xử lý Ngôn ngữ Tự nhiên (NLP) và Trí tuệ Nhân tạo:

- google-generativeai>=0.8.3: Thư viện SDK chính thức của Google để giao tiếp với API của mô hình Gemini (tạo sinh, phân loại ý định, làm mượt văn bản).
- underthesea==6.8.0: Bộ công cụ xử lý ngôn ngữ tự nhiên chuyên dụng cho tiếng Việt, đảm nhiệm khâu phân tách từ (Word Segmentation).

3. Nhóm Thuật toán, Toán học và Học máy:

- networkx==3.2.1: Cung cấp cấu trúc dữ liệu và thuật toán đồ thị, phục vụ cho quá trình tính toán PageRank trong thuật toán TextRank.
- scikit-learn==1.4.0: Hỗ trợ mã hóa vector TF-IDF và tính toán độ tương đồng Cosine (Cosine Similarity).

4. Nhóm Xử lý và Trực quan hóa Dữ liệu:

- pandas==2.2.0 & numpy==1.26.4: Xử lý ma trận dữ liệu, cấu trúc DataFrame.
- matplotlib>=3.7.0 & seaborn>=0.12.0: Vẽ biểu đồ và trực quan hóa các kết quả thực nghiệm.
- datasets>=2.14.0: Tải và quản lý tập dữ liệu chuẩn hóa XLSum từ HuggingFace.

5. Nhóm Xử lý tệp tin Tài liệu (PDF, Word):

- PyPDF2==3.0.1 & PyMuPDF>=1.23.0: Trích xuất văn bản thô từ giáo trình định dạng PDF.
- python-docx==1.1.0: Đọc và bóc tách dữ liệu từ file Word.
- fpdf2==2.7.7: Hỗ trợ xuất kết quả tóm tắt ra tệp PDF mới.

6. Nhóm Đánh giá và Tiện ích hệ thống:

- rouge-score==0.1.2: Tính toán các độ đo N-gram (ROUGE-1, ROUGE-2, ROUGE-L) để đánh giá chất lượng tóm tắt.
- python-dotenv==1.0.0: Quản lý các biến môi trường bảo mật (như API Key).
- tqdm>=4.66.0: Hiển thị thanh tiến trình trực quan trong quá trình thực nghiệm.

Nội dung tệp requirements.txt gốc của dự án:

```
streamlit==1.29.0
numpy==1.26.4
scikit-learn==1.4.0
google-generativeai>=0.8.3
python-dotenv==1.0.0
underthesea==6.8.0
PyPDF2==3.0.1
python-docx==1.1.0
networkx==3.2.1
rouge-score==0.1.2
fpdf2==2.7.7
pandas==2.2.0
PyMuPDF>=1.23.0
matplotlib>=3.7.0
seaborn>=0.12.0
datasets>=2.14.0
tqdm>=4.66.0
streamlit-pdf-viewer>=0.0.10
```

PHỤ LỤC B: CẤU TRÚC CHỈ THỊ (PROMPT ENGINEERING)

Các kỹ thuật thiết kế chỉ thị (Prompt) dưới đây được sử dụng để điều khiển hành vi của Mô hình Ngôn ngữ Lớn (Gemini), đảm bảo tính trung thực và ngăn chặn rủi ro ảo giác thông tin (Hallucination).

B.1. System Prompt cho chức năng Tóm tắt Lại (Hybrid Summarization)

Được gọi sau khi thuật toán TextRank đã trích xuất xong tập hợp các câu thô.

[SYSTEM INSTRUCTION] Bạn là một chuyên gia học thuật trong lĩnh vực Hệ thống Thông tin. Nhiệm vụ của bạn là tổng hợp và viết lại các câu dưới đây thành một đoạn văn tóm tắt mạch lạc, dễ hiểu cho sinh viên.

QUY TẮC RÀNG BUỘC TUYỆT ĐỐI:

1. CHỈ sử dụng các dữ kiện có trong phần [VĂN BẢN TRÍCH XUẤT].
2. KHÔNG ĐƯỢC thêm bớt, suy diễn hay sử dụng kiến thức bên ngoài của bạn.
3. Tuyệt đối giữ nguyên các thuật ngữ kỹ thuật tiếng Anh (ví dụ: Database, Agile, Router...).
4. Văn phong khách quan, học thuật, không xưng hô.

[VĂN BẢN TRÍCH XUẤT] {extractive_text}

B.2. System Prompt cho chức năng Đánh giá LLM-as-a-Judge (Faithfulness)

Sử dụng để chấm điểm tự động hệ thống RAG trong Kịch bản thực nghiệm 3.

[SYSTEM INSTRUCTION] Bạn là một giám khảo khách quan. Nhiệm vụ của bạn là đánh giá xem "Câu trả lời của AI" có hoàn toàn trung thực và dựa trên "Ngữ cảnh được truy xuất" hay không. Hãy chấm điểm Độ trung thực (Faithfulness) theo thang điểm từ 1 đến 5:

- Điểm 5: Hoàn hảo. Mọi thông tin đều nằm trong Ngữ cảnh.
- Điểm 4: Tốt. Đúng ý nhưng có thể hơi diễn đạt khác.
- Điểm 3: Trung bình. Chỉ đúng một phần.
- Điểm 2: Kém. Bịa đặt một phần thông tin.
- Điểm 1: Sai hoàn toàn. Trả lời lạc đề hoặc bịa đặt toàn bộ.

Chỉ in ra màn hình MỘT CON SỐ DUY NHẤT (từ 1 đến 5), không giải thích gì thêm.

[NGỮ CẢNH ĐƯỢC TRUY XUẤT] {context_text} [CÂU TRẢ LỜI CỦA AI] {ai_generated_answer}

PHỤ LỤC C: TRÍCH ĐOẠN DỮ LIỆU THỰC NGHIỆM

C.1. Trích đoạn Từ điển chuyên ngành HTTT (Domain Dictionary)

Từ điển chuyên ngành (Domain Dictionary) đầy đủ gồm hàng ngàn thuật ngữ được lưu trữ nội bộ để phục vụ cho biến base_bonus. Dưới đây là trích đoạn ngẫu nhiên (nạp từ file it_dictionary.txt):

- an toàn thông tin
- api
- bộ chuyển mạch
- bộ định tuyến
- cassandra
- cơ sở dữ liệu nosql
- cơ sở dữ liệu quan hệ
- chuẩn hóa dữ liệu
- chữ ký số
- hệ quản trị cơ sở dữ liệu
- máy học
- quy trình phát triển phần mềm
- tích hợp hệ thống
- xử lý ngôn ngữ tự nhiên

C.2. Trích đoạn kết quả đánh giá LLM-as-a-Judge đối với phân hệ RAG

Dữ liệu đối chiếu kết quả sinh văn bản của hệ thống RAG với đáp án chuẩn của chuyên gia (Trích xuất từ file kết quả thực nghiệm rag_results_to_evaluate.csv).

STT	Câu hỏi từ người dùng	Đáp án hệ thống tạo sinh (System Answer)	Trạng thái / Đánh giá
1	Khái niệm RAG là gì?	RAG là sự kết hợp giữa truy xuất thông tin (Retrieval) và tạo sinh văn bản (Generation) để cải thiện độ chính xác của LLMs.	Khớp (Điểm 5)
2	Kể tên các loại cơ sở dữ liệu NoSQL phổ biến?	Các loại phổ biến bao gồm Document Store (MongoDB), Key-Value (Redis), Column-Family (Cassandra), Graph (Neo4j).	Khớp (Điểm 5)
3	Lỗi False negative trong an ninh mạng là gì?	Là lỗi hệ thống nhận nhầm một hành vi hợp lệ thành một cuộc tấn công.	Khác (False Positive)
4	Mã hóa đối xứng và bất đối xứng khác nhau thế nào?	Mã hóa đối xứng dùng chung 1 khóa. Bất đối xứng dùng 1 khóa công khai và 1 khóa bí mật.	Khớp (Điểm 5)
5	Các tính chất của ACID trong cơ sở dữ liệu?	Gồm: Atomicity (Tính nguyên tử), Consistency (Tính nhất quán), Isolation (Tính cô lập), Durability (Tính bền vững).	Khớp (Điểm 5)